



UNIVERSITÀ DEGLI STUDI DI FIRENZE
SCUOLA DI INGEGNERIA - DIPARTIMENTO DI INGEGNERIA
DELL'INFORMAZIONE

Tesi di Laurea Triennale in Ingegneria Informatica

SPEECH TO POSE
PREDIZIONE DELLA POSA DELLA TESTA A
PARTIRE DAL PARLATO PER L'ANIMAZIONE DI
TALKING HEADS 3D

Candidato
Niccolò Cortini

Relatore
Prof. Stefano Berretti

Correlatori
Dr. Claudio Ferrari
Dr. Federico Nocentini

Anno Accademico 2025/2026

Indice

1	Introduzione	1
1.1	Struttura della tesi	3
2	Lavori Correlati	5
2.1	Animazione Facciale 3D Guidata dal Parlato	5
2.2	Predizione della Posa della Testa dall'Audio	8
2.3	Posizionamento del Lavoro Proposto	9
3	Metodo Proposto	11
3.1	Panoramica dell'Architettura	11
3.1.1	Encoder Audio: Wav2Vec 2.0	13
3.1.2	LSTM Bidirezionale	15
3.1.3	Funzione di Errore	16
3.2	Il Dataset Mead-EMOTE	18
3.2.1	Pre-processamento	19
4	Esperimenti	23
4.0.1	Setup Sperimentale	23
4.1	Primi addestramenti (EXP1 e EXP2)	26
4.2	EXP3 – Analisi dell'Impatto della Velocity Loss	26
4.3	EXP4 – Standardizzazione della Velocity Loss	30

4.4	EXP5 – Filtro Savitzky-Golay e Tuning dell'Architettura LSTM	33
4.5	EXP6 – Overfitting Intenzionale	39
4.6	EXP7 – Adozione del Dataset HDTF-TFHP	44
4.7	EXP8 – Il modello Variational Autoencoder	50
4.8	EXP9 – One-Hot Encoding degli Speaker	54
4.9	EXP10 – Il termine di costo FaceLoss	57
4.10	EXP11 – Il termine di costo VarLoss	60
4.11	EXP12 – Standardizzazione della VarLoss	64
5	Conclusioni e Sviluppi Futuri	69
5.1	Conclusioni	69
5.2	Sviluppi Futuri	70
	Bibliografia	71

Capitolo 1

Introduzione

Il volto umano è un canale espressivo fondamentale nella comunicazione interpersonale. Oltre alle parole, il comportamento facciale comunica emozioni, intenzioni e identità, e gioca un ruolo cruciale nel modo in cui gli esseri umani si percepiscono e si capiscono reciprocamente. Per questo, la capacità di modellare e animare in modo realistico il movimento facciale è diventata un obiettivo centrale nella ricerca in computer vision e computer grafica.

Negli ultimi anni, la diffusione di avatar digitali, assistenti virtuali, applicazioni di video production e sistemi di interazione real-time ha reso la generazione di animazioni facciali realistiche un problema di crescente rilevanza applicativa. Un umano digitale con un'animazione poco convincente compromette immediatamente la comunicazione e la percezione di naturalezza da parte dell'osservatore.

In tale panorama, l'animazione facciale 3D guidata dal parlato, comunemente denominata *3D Talking Heads*, è emersa come un problema particolarmente rilevante e complesso. L'obiettivo consiste nell'animare una mesh 3D del volto a partire da un segnale audio, producendo un movimento facciale temporalmente coerente e sincronizzato con il parlato, preservando al

contempo l'identità del soggetto e la naturalezza visiva. A differenza degli approcci 2D, che operano direttamente su immagini o video, i metodi 3D rappresentano la geometria del volto come una mesh tridimensionale. Questo consente di modificare liberamente il punto di vista e di integrare l'animazione in ambienti virtuali, rendendola più versatile e riutilizzabile.

All'interno di questo campo, un aspetto tradizionalmente trascurato è il movimento della testa. Un avatar che muove le labbra in modo sincronizzato ma mantiene la testa perfettamente immobile risulta immediatamente artificiale alla percezione dell'osservatore: cenni del capo, inclinazioni laterali e rotazioni accompagnano naturalmente il discorso e contribuiscono in modo significativo alla percezione di naturalezza del parlante. Il presente lavoro si propone di colmare questa lacuna, affiancando a ScanTalk [6], un sistema sviluppato presso il MICC dell'Università di Firenze per l'animazione delle labbra 3D, un modulo dedicato alla predizione automatica dell'*head pose*: la rotazione rigida della testa nei tre assi principali, *pitch*, *yaw* e *roll*, a partire dallo stesso segnale audio. Le uscite dei due moduli vengono combinate frame per frame sulla mesh 3D per produrre un'animazione facciale completa e più naturale.

Nonostante i progressi recenti, il task presenta alcune sfide fondamentali che ne limitano le soluzioni esistenti.

Una prima sfida riguarda la natura intrinsecamente ambigua della relazione tra segnale audio e movimento della testa. La medesima frase può essere pronunciata con sequenze di pose radicalmente diverse da persona a persona, o dalla stessa persona in momenti diversi: a un dato segnale audio non corrisponde una singola sequenza di pose, bensì una distribuzione di sequenze ugualmente plausibili, condizionata dalla personalità del parlante e dal contesto comunicativo. Di conseguenza, un modello supervisionato addestrato

su dati provenienti da soggetti eterogenei si trova a dover associare uno stesso segnale audio a target tra loro molto diversi, rendendo la definizione di un obiettivo di apprendimento stabile una sfida aperta.

Una seconda difficoltà, strettamente connessa alla precedente, è rappresentata dal fenomeno noto come *regression to the mean*. Un modello deterministico addestrato a minimizzare l'errore quadratico medio (MSE, dall'inglese Mean Squared Error) tende a convergere verso la media delle traiettorie osservate durante il training. Il risultato pratico è che la testa tende a restare quasi ferma sugli assi di partenza, con movimenti di ampiezza trascurabile: una predizione che, di fatto, non aggiunge informazione utile rispetto all'assenza di movimento.

Una terza criticità riguarda la scarsità dei dati disponibili per questo task. A differenza di altri campi della visione artificiale, la predizione dell'*head pose* guidata dall'audio dispone di dataset relativamente piccoli, con un numero limitato di soggetti e di stili di parlato. Questa scarsità rende difficile apprendere pattern di movimento sufficientemente generali, aumentando il rischio di un modello che funziona bene solo su ciò che ha già osservato.

1.1 Struttura della tesi

Il **Capitolo 2** colloca il lavoro all'interno della letteratura scientifica esaminando l'evoluzione dei sistemi di animazione facciale 3D guidata dal parlato.

Il **Capitolo 3** descrive nel dettaglio le componenti e l'architettura del modulo *SpeechToPose*.

Il **Capitolo 4** delinea, attraverso dodici esperimenti, una storia evolutiva caratterizzata da cambiamenti progressivi mirati a migliorare la qualità della

predizione.

Il **Capitolo 5** sintetizza le conclusioni dell'indagine evidenziando i limiti delle scelte effettuate e delineando i possibili sviluppi futuri.

Capitolo 2

Lavori Correlati

Questa sezione analizza la letteratura di riferimento per il progetto, organizzata per aree tematiche. Partiremo dall'evoluzione dei sistemi di animazione facciale 3D guidata dal parlato (*speech-driven 3D talking heads*), evidenziandone successi e limitazioni. Passeremo poi allo stato dell'arte sulla predizione della posa della testa (*head pose*) dall'audio, il cuore di questo studio. Concluderemo motivando le scelte progettuali del nostro sistema alla luce dei lavori finora esaminati.

2.1 Animazione Facciale 3D Guidata dal Parlato

Negli ultimi anni, la generazione di animazioni facciali 3D guidate dall'audio ha compiuto enormi progressi, spinta dall'uso di dataset di scansioni 4D e potenti encoder audio pre-addestrati. I tradizionali metodi procedurali, legati a visemi e regole fonetiche [2], sono stati ampiamente superati dai modelli di deep learning. Questi ultimi riescono infatti a catturare dinamiche di movimento molto più complesse e specifiche per ogni singolo soggetto.

VOCA [2] ha segnato un vero e proprio punto di svolta in questo campo. Addestrandolo su diversi parlatori, gli autori hanno provato che è possibile slegare i movimenti della bocca dall'identità del soggetto, permettendo al modello di generalizzare su volti nuovi. Il sistema sfrutta **FLAME** [5] per ottenere una geometria 3D compatta del viso, tracciando una strada seguita da quasi tutta la ricerca successiva. Purtroppo, VOCA si limita a muovere solo la regione labiale, lasciando la testa del tutto immobile.

La ricerca successiva ha puntato su architetture capaci di catturare meglio l'espressività umana. **FaceFormer** [4] ha innovato il campo sostituendo le reti ricorrenti con un Transformer autoregressivo, sfruttando la *biased cross-modal attention* per un allineamento audio-volto più rigoroso. **CodeTalker** [15] ha fatto un ulteriore passo avanti affrontando il problema della *regressione alla media*: la tendenza dei modelli deterministici (addestrati con loss MSE) a produrre animazioni medie e inespressive. L'idea di CodeTalker è introdurre un *discrete motion prior* (tramite un codebook VQ-VAE) che obbliga le predizioni a rientrare in uno spazio limitato di movimenti plausibili, evitando così la piattezza tipica della media matematica. Poiché questa limitazione dei modelli deterministici tocca da vicino anche le scelte architettureali di questo lavoro, l'argomento verrà ripreso e approfondito nella discussione degli esperimenti.

Il passaggio definitivo verso un approccio puramente generativo si è concretizzato con l'avvento dei modelli di diffusione. Il primo a portare questa tecnologia nel mondo dell'animazione facciale 3D è stato **FaceDiffuser** [10], che è riuscito a generare sequenze di altissima qualità svincolandosi finalmente dai limiti dei modelli deterministici. Su questa stessa scia si inserisce **DiffPoseTalk** [12], che ha ampliato le potenzialità della diffusione usando-la per animare all'unisono sia le espressioni del viso che i movimenti della

testa. Torneremo ad analizzare quest'ultimo modello più nel dettaglio nella prossima sezione.

I contributi MICC: S2L-S2D e ScanTalk. In questo vivace panorama di ricerca si inseriscono i contributi sviluppati al MICC dell'Università di Firenze. Tra questi spicca **S2L-S2D** [7], proposto da Nocentini, Ferrari e Berretti. Il modello adotta una strategia a due stadi (in gergo *coarse-to-fine*): prima utilizza una rete LSTM bidirezionale per stimare i movimenti di 68 punti chiave del volto (*Speech-to-Landmarks*), e in un secondo momento trasforma queste tracce in un movimento denso su tutta la mesh 3D, sfruttando convoluzioni spirali e operazioni di *up-sampling* (*Speech-to-Dense*). Un'intuizione interessante di questo lavoro è l'introduzione di una *Cosine Loss*, pensata per mantenere i movimenti geometricamente coerenti dando più importanza alla direzione dello spostamento piuttosto che alla sua intensità assoluta. Tuttavia, esattamente come VOCA, anche S2L-S2D si concentra solo sul volto, trascurando del tutto la modellazione indipendente della posa della testa.

ScanTalk [6], presentato a ECCV 2024, ha fatto cadere uno dei vincoli più rigidi di questo settore: l'obbligo di usare mesh con la stessa identica topologia sia in fase di addestramento che di test. Il segreto sta nell'utilizzo di **DiffusionNet** [9], un'architettura capace di estrarre descrittori geometrici direttamente dalla superficie 3D (sfruttando l'operatore di Laplace-Beltrami) senza aver bisogno di mappare i vertici uno a uno. Grazie a questa intuizione, ScanTalk è in grado di animare qualsiasi volto 3D, comprese le scansioni grezze reali, senza richiedere alcun preprocessing. Questa straordinaria capacità di adattarsi a geometrie sconosciute (*zero-shot generalization*) è il vero motore tecnologico su cui si poggia il nostro lavoro. Tuttavia, proprio come

i suoi predecessori, anche ScanTalk si concentra solo sulle espressioni, lasciando la testa immobile. Il nostro progetto nasce esattamente per colmare questa specifica lacuna.

2.2 Predizione della Posa della Testa dall'Audio

Animare i movimenti rigidi della testa, tipicamente descritti dai tre angoli di rotazione *pitch*, *yaw* e *roll*, rappresenta una sfida profondamente diversa dalla semplice sincronizzazione labiale. Tra voce e movimento del capo esiste infatti una correlazione debole, poiché una stessa frase può generare inclinazioni e scatti completamente differenti in base a chi parla, al suo umore e al suo stile comunicativo. Questa ambiguità, nota come *one to many*, rende la predizione un problema intrinsecamente probabilistico, svelando i limiti strutturali dei classici modelli deterministici.

In ambito 2D, **Audio2Head** [14] propone una soluzione concettualmente molto vicina alla nostra. L'architettura delega a una rete ricorrente *motion aware* il compito di calcolare esplicitamente la posa della testa, isolandola del tutto dalle espressioni facciali; solo in un secondo momento le due dinamiche vengono fuse per generare il video finale. Questa scelta di separare nettamente l'identità del movimento rigido da quella espressiva è esattamente il paradigma su cui si fonda il nostro sistema 3D. Tornando al mondo 3D, **DiffPoseTalk** [12] è oggi il modello di riferimento per generare contemporaneamente le espressioni e i movimenti della testa a partire dalla voce. Per risolvere il problema dell'ambiguità *one to many*, il sistema utilizza i modelli di diffusione, riuscendo a creare animazioni sempre diverse e molto naturali. Lo stile personale di chi parla viene semplicemente catturato da un video di

esempio e applicato al modello facciale FLAME [5]. DiffPoseTalk dimostra chiaramente quanto il movimento della testa sia essenziale per ottenere un effetto davvero realistico, ma ha un grosso limite pratico. Il suo meccanismo matematico richiede infatti un'enorme potenza di calcolo, rendendolo di fatto inutilizzabile per tutte quelle applicazioni che hanno bisogno di risposte immediate o che dispongono di poche risorse hardware.

2.3 Posizionamento del Lavoro Proposto

Il sistema presentato nei capitoli successivi si propone di integrare la predizione del movimento della testa all'interno del framework ScanTalk.

Come si è visto ripercorrendo l'evoluzione da VOCA fino a DiffPoseTalk, la ricerca si sta spingendo verso modelli sempre più complessi e pesanti dal punto di vista computazionale. Il presente lavoro, invece, prende volutamente una direzione opposta. Si è scelto di puntare su un'architettura deterministica molto più leggera ed efficiente, basata su una LSTM bidirezionale. L'idea di fondo non è competere con i modelli generativi sulla varietà dei movimenti, ma creare un modulo pratico, rapido e facilmente integrabile in flussi di lavoro già esistenti.

Infine, l'integrazione del modulo **SpeechToPose** con ScanTalk dà vita a un sistema che, allo stato attuale della ricerca, risulta inedito. Per quanto noto, è infatti il primo in letteratura a combinare un'animazione facciale guidata dal parlato su mesh a topologia arbitraria con una predizione esplicita dei movimenti della testa. Il progetto si distingue sia dai metodi vincolati a topologie fisse (come VOCA, FaceFormer e DiffPoseTalk), sia da quelli che ignorano del tutto la dinamica della testa (come ScanTalk e S2L-S2D).

Capitolo 3

Metodo Proposto

Il presente capitolo descrive nel dettaglio il metodo proposto per la predizione automatica dell'*head pose* a partire da un segnale audio. Viene illustrata l'architettura del modulo **SpeechToPose**, con particolare attenzione alla pipeline end-to-end che collega l'ingresso audio alle sequenze di angoli di rotazione previsti. Vengono inoltre presentate la formulazione matematica della funzione di errore adottata e le procedure di pre-processamento.

3.1 Panoramica dell'Architettura

Il sistema proposto è organizzato come una pipeline modulare in cui il modulo **SpeechToPose** viene affiancato, in modo indipendente, al sistema ScanTalk [6] già sviluppato presso il MICC dell'Università di Firenze. ScanTalk si occupa della generazione del movimento delle labbra a partire dall'audio, mentre il modulo qui descritto predice la rotazione della testa. Le uscite dei due moduli vengono poi combinate *frame per frame* sulla mesh 3D del soggetto, producendo un'animazione facciale completa.

In modo schematico, dato un segnale audio grezzo $\mathbf{a} \in \mathbb{R}^{T_a}$ campionato a 16 kHz, il modulo produce in uscita una sequenza di T_p triplette di angoli di rotazione:

$$\hat{\mathbf{P}} = (\hat{p}_1, \hat{p}_2, \dots, \hat{p}_{T_p}), \quad \hat{p}_t = (\hat{\theta}_t^{\text{pitch}}, \hat{\theta}_t^{\text{yaw}}, \hat{\theta}_t^{\text{roll}}) \in \mathbb{R}^3.$$

La sequenza $\hat{\mathbf{P}}$ viene successivamente applicata alla mesh 3D tramite rotazioni rigide, consentendo la generazione di un'animazione 3D del movimento della testa coerente con il segnale di parlato in ingresso.

La pipeline di **SpeechToPose** è composta da tre stadi principali:

1. **Estrazione delle feature audio:** il segnale grezzo viene elaborato dall'encoder pre-addestrato Wav2Vec 2.0, il cui output è una sequenza di rappresentazioni contestuali di dimensione 768 a una frequenza di circa 50 frame al secondo.
2. **Predizione temporale:** le feature audio vengono elaborate da una rete LSTM bidirezionale multi-layer per catturare le dipendenze temporali e produrre una rappresentazione contestuale per ciascun frame.
3. **Regressione della posa:** un livello lineare finale mappa la rappresentazione LSTM ai tre angoli di rotazione per ogni frame.




Figura 3.1: Pipeline del modulo **SpeechToPose**. Il segnale audio grezzo (16 kHz) viene codificato dal blocco Wav2Vec 2.0 (compressione in feature a ~ 50 Hz), normalizzato e interpolato a 30 fps, elaborato dalla Bi-LSTM e infine proiettato dallo strato FC ai tre angoli di rotazione (pitch, yaw, roll) per ogni frame.




Figura 3.2: Integrazione del modulo **SpeechToPose** con ScanTalk. Lo stesso segnale audio viene fornito in ingresso a entrambi i moduli in parallelo: **SpeechToPose** produce la sequenza di angoli di rotazione della testa, mentre ScanTalk genera il movimento delle labbra come deformazione dei vertici della mesh. Le uscite dei due moduli vengono combinate *frame per frame* sulla mesh 3D del soggetto, producendo un'animazione facciale completa.

3.1.1 Encoder Audio: Wav2Vec 2.0

Come encoder per le rappresentazioni audio, si adotta Wav2Vec 2.0 [1], un modello Transformer pre-addestrato su 960 ore di parlato in lingua inglese (corpus LibriSpeech). Wav2Vec 2.0 è composto da due componenti principali: un estrattore di feature convoluzionale che riduce la forma d'onda grezza in una sequenza di rappresentazioni locali, e una serie di blocchi Transformer. L'uscita dell'encoder è una sequenza di vettori di dimensione 768, a una frequenza di circa 50 Hz.

Nel sistema proposto, l'utilizzo dell'encoder Wav2Vec 2.0 è stato esplorato sperimentando due approcci: il *partial fine-tuning* e il *full freeze*. Nel primo approccio (*partial fine-tuning*), il CNN feature extractor viene mantenuto congelato, mentre gli ultimi 4 blocchi Transformer (layer 8–11 su 12 totali) vengono sbloccati e resi addestrabili. Questo consente alle rappresentazioni ad alto livello di adattarsi alle dinamiche acustiche specificamente associate ai movimenti della testa, a scapito però di un maggior numero di parametri

addestrabili. Nel secondo approccio, i pesi di Wav2Vec 2.0 sono mantenuti completamente congelati (*full freeze*): l'intero modello, inclusi sia il CNN feature extractor sia tutti i blocchi Transformer, è mantenuto fisso durante l'addestramento. Solo i parametri della rete LSTM e dello strato di output vengono aggiornati dalla procedura di ottimizzazione.

Gestione della durata dei file Un problema pratico affrontato durante lo sviluppo riguarda il disallineamento temporale tra i file audio (`.wav`) e i file delle pose (`.npy`), spesso causato da code di silenzio o discrepanze di formato. Nella prima fase del progetto avevamo scelto di tagliare il segnale manualmente per forzare una lunghezza identica tra le due fonti. Successivamente abbiamo preferito affidare questo compito direttamente al modello; il segnale vocale non subisce alcun taglio preventivo ma viene passato per intero a Wav2Vec 2.0. Fornire l'audio nella sua interezza permette alla rete di analizzare la sequenza senza subire perdite di informazione dovute a tagli netti, lasciandole la libertà di capire in totale autonomia quali parti della voce siano più rilevanti per il movimento.

Formalmente, definendo come $\mathbf{a} \in \mathbb{R}^{T_a}$ il segnale audio normalizzato nel dominio del tempo, l'encoder f_{W2V} produce la sequenza di feature

$$\mathbf{F} = f_{W2V}(\mathbf{a}) \in \mathbb{R}^{T_f \times 768}$$

dove T_f rappresenta la durata della sequenza acustica espressa in frame a 50 Hz.

Allineamento temporale audio-pose. Poiché la frequenza di campionamento dell'encoder audio (circa 50 Hz) non coincide in generale con la frequenza dei frame video a cui sono associate le pose target (30 fps), si rende necessario un allineamento temporale. A tale scopo, dopo l'estrazione

delle feature audio, si applica un'interpolazione lineare lungo l'asse temporale per portare la sequenza $\mathbf{F}$ alla lunghezza T_p della sequenza di posa:

$$\mathbf{F}' = \text{Interp}(\mathbf{F}, T_p) \in \mathbb{R}^{T_p \times 768}.$$

Questo approccio delega interamente all'encoder il compito di determinare la struttura temporale delle feature, evitando qualsiasi taglio manuale del segnale audio che introdurrebbe un disallineamento sistematico tra l'ingresso e il target da predire. In presenza di batch con sequenze di durata variabile, la lunghezza target T_p è pari alla lunghezza della sequenza di posa più lunga nel batch (si veda la Sezione 3.2 per i dettagli sul padding).

Layer Normalization. Prima dell'interpolazione temporale, le feature $\mathbf{F} \in \mathbb{R}^{T_f \times 768}$ già estratte da Wav2Vec 2.0 (ancora alla frequenza originale di circa 50 Hz) vengono sottoposte a una normalizzazione per strato (*Layer Normalization*), applicata indipendentemente su ciascun passo temporale lungo la dimensione delle feature (768). Questa operazione stabilizza la distribuzione degli input e favorisce la convergenza durante l'addestramento. Solo dopo la normalizzazione le feature vengono interpolate a 30 fps e passate alla rete LSTM.

3.1.2 LSTM Bidirezionale

La componente temporale del sistema è una rete ricorrente a memoria di breve e lunga durata (*Long Short-Term Memory*, LSTM) bidirezionale con L layer impilati. La scelta di un'architettura ricorrente è motivata dalla natura intrinsecamente sequenziale del task. Il movimento della testa in un dato istante dipende infatti non solo dalle feature audio correnti ma anche dal contesto temporale che le precede e le segue. La direzionalità doppia consente

alla rete di elaborare ogni frame conoscendo sia la storia acustica passata sia quella futura, producendo per ogni istante un vettore di attivazioni che sintetizza l'intera sequenza in ingresso.

Formalmente, partendo dall'ingresso normalizzato $\mathbf{F}' \in \mathbb{R}^{T_p \times 768}$, la LSTM bidirezionale con L layer e dimensione nascosta H calcola l'uscita

$$\mathbf{Z} = \text{BiLSTM}_{L,H}(\mathbf{F}') \in \mathbb{R}^{T_p \times 2H}$$

dove il fattore moltiplicativo 2 è dovuto alla concatenazione dei risultati delle direzioni *forward* e *backward*. Sul tensore $\mathbf{Z}$ viene applicato un *dropout* con probabilità p_d prima di passare al livello successivo.

Lo strato di regressione finale è un livello completamente connesso che genera i tre angoli di rotazione per ciascun frame applicando la formula

$$\hat{\mathbf{P}} = \mathbf{Z}\mathbf{W}^\top + \mathbf{b}, \quad \mathbf{W} \in \mathbb{R}^{3 \times 2H}, \quad \mathbf{b} \in \mathbb{R}^3$$

L'uscita finale $\hat{\mathbf{P}} \in \mathbb{R}^{T_p \times 3}$ rappresenta l'insieme delle triplette di angoli di rotazione predetti, ovvero *pitch*, *yaw* e *roll*, per ogni singolo istante della sequenza.

3.1.3 Funzione di Errore

La procedura di addestramento ottimizza una funzione di errore composta, denominata **PoseLoss**, che combina un termine di fedeltà sulla posizione assoluta degli angoli con un termine opzionale di regolarizzazione sulla velocità angolare.

Position Loss. Il termine principale è l'errore quadratico medio (*Mean Squared Error*, MSE) tra la sequenza di pose predette $\hat{\mathbf{P}}$ e la sequenza target $\mathbf{P}$. Poiché le sequenze nel batch possono essere di lunghezza variabile e

vengono allineate tramite zero-padding (si veda la Sezione 3.2.1), la loss viene calcolata esclusivamente sui frame reali, ignorando completamente i frame paddati. Sia $\mathcal{M}_t \in \{0, 1\}$ la maschera booleana tale che $\mathcal{M}_t = 1$ se il frame t è reale e $\mathcal{M}_t = 0$ se è un frame di padding. La position loss è definita come:

$$\mathcal{L}_{\text{pos}} = \frac{1}{\sum_{b,t} \mathcal{M}_{b,t}} \sum_{b=1}^B \sum_{t=1}^{T_p} \mathcal{M}_{b,t} \|\hat{p}_{b,t} - p_{b,t}\|_2^2,$$

dove B è la dimensione del batch, $\hat{p}_{b,t} \in \mathbb{R}^3$ è la posa predetta per il campione b al frame t e $p_{b,t} \in \mathbb{R}^3$ è la posa target corrispondente.

Velocity Loss. Il secondo termine penalizza le discontinuità nella traiettoria temporale predetta, ossia le variazioni brusche di posa tra frame consecutivi (*jittering*). A tale scopo si calcolano le derivate discrete (differenze finite) della sequenza predetta e della sequenza target lungo l'asse temporale:

$$\Delta \hat{p}_{b,t} = \hat{p}_{b,t+1} - \hat{p}_{b,t}, \quad \Delta p_{b,t} = p_{b,t+1} - p_{b,t}.$$

La velocity loss è l'MSE tra queste differenze, calcolata solo nei passi temporali in cui entrambi i frame adiacenti t e $t + 1$ sono reali:

$$\mathcal{L}_{\text{vel}} = \frac{1}{\sum_{b,t} \mathcal{V}_{b,t}} \sum_{b=1}^B \sum_{t=1}^{T_p-1} \mathcal{V}_{b,t} \|\Delta \hat{p}_{b,t} - \Delta p_{b,t}\|_2^2,$$

dove $\mathcal{V}_{b,t} = \mathcal{M}_{b,t} \wedge \mathcal{M}_{b,t+1}$ è la maschera delle coppie di frame entrambi reali.

Loss Totale. La funzione di errore complessiva è una combinazione lineare pesata dei due termini:

$$\mathcal{L}_{\text{tot}} = \mathcal{L}_{\text{pos}} + \lambda_{\text{vel}} \cdot \mathcal{L}_{\text{vel}},$$

dove $\lambda_{\text{vel}} \geq 0$ è un iperparametro che controlla il peso relativo del termine di velocità. Il ruolo e l'impatto di questo parametro vengono analizzati sperimentalmente nel Capitolo 4.2.

3.2 Il Dataset Mead-EMOTE

Il corpus di dati utilizzato per condurre i primi esperimenti di questo lavoro è stato preparato e fornito dal correlatore di tesi Federico Nocentini all'interno delle attività del gruppo di ricerca MICC dell'Università di Firenze. La raccolta deriva da MEAD [13], un noto archivio video di parlato emotivo in lingua inglese acquisito in condizioni visive e acustiche strettamente controllate. L'intero dataset comprende 48 soggetti impegnati a pronunciare circa 30 frasi brevi sia in modo neutrale sia recitando sette emozioni di base (rabbia, disgusto, paura, felicità, disprezzo, tristezza e sorpresa) articolate su tre differenti livelli di intensità.

Poiché la versione originale di MEAD non fornisce mesh 3D abbinate all'audio, la geometria facciale è stata ricavata sotto forma di *pseudo-ground truth* attraverso l'algoritmo EMOTE [3]. Questo metodo applica avanzate tecniche di ricostruzione tridimensionale monoculare ai fotogrammi video per poi ottimizzarle in modo specifico sui soggetti del dataset. Il risultato finale è una ricca raccolta di sequenze facciali 3D registrate e perfettamente sincronizzate con il rispettivo segnale vocale.

A livello strutturale i dati sono stati organizzati in quattro directory principali, ciascuna con un ruolo ben definito all'interno della pipeline. La cartella **audio** contiene i segnali vocali utilizzati come ingresso del modello durante il training, mentre la cartella **pose** raccoglie le sequenze dei movimenti estratti dai video ed espressi tramite gli angoli di *pitch*, *yaw* e *roll*. Queste rotazioni costituiscono il vero e proprio target di supervisione per il modulo **SpeechToPose**. Le restanti due cartelle sono invece dedicate esclusivamente alla fase di valutazione. In particolare **vertices** ospita le mesh facciali 3D neutre da usare come base per generare le animazioni di test con il sistema completo, mentre **vertice_pose** contiene le geometrie su cui è stata appli-

cata la rotazione originale della testa. Queste ultime fungono da riferimento per valutare quantitativamente e qualitativamente la qualità dell'animazione predetta.

Divisione del Dataset

La partizione in insiemi di addestramento, validazione e test avviene esclusivamente a livello di soggetto. Se la divisione venisse fatta per singole sequenze, il modello potrebbe finire per imparare lo stile di un parlatore durante il training per poi replicarlo in fase di test. Per evitare *data leakage*, tutti i file relativi a una stessa identità vengono assegnati in blocco allo stesso sottoinsieme.

Per definire questa partizione in modo rigoroso tutti gli N soggetti presenti nel dataset vengono ordinati in modo deterministico e assegnati ai tre gruppi seguendo proporzioni fisse. Nello specifico l'80% delle identità viene destinato alla fase di addestramento, il 10% serve per la validazione e il restante 10% viene isolato per i test finali. L'utilizzo di un ordinamento deterministico prima della divisione garantisce che gli esperimenti siano sempre esattamente riproducibili.

3.2.1 Pre-processamento

Filtro Savitzky-Golay

Il processo di estrazione automatica degli angoli dai video originali introduce inevitabilmente un rumore ad alta frequenza all'interno delle sequenze. Se lasciato inalterato questo disturbo viene direttamente assimilato dal modello durante il training. La rete finirebbe infatti per imparare a replicare

i microscatti del segnale target, producendo in fase di inferenza traiettorie affette dallo stesso fenomeno di *jittering* osservato nei dati di partenza.

Per attenuare questo effetto applichiamo alle pose target un filtro passa basso di tipo **Savitzky-Golay** [8]. Questo algoritmo realizza uno *smoothing* locale del segnale operando su finestre scorrevoli. Ad ogni istante temporale i valori contenuti in una finestra di ampiezza w vengono approssimati ai minimi quadrati da un polinomio di grado d e il nuovo valore filtrato corrisponde semplicemente alla valutazione di tale polinomio nel punto centrale della finestra.

Formalmente, definendo come $p_t^{(k)}$ il segnale corrispondente al k -esimo angolo di posa al frame t , il valore filtrato si ottiene tramite l'espressione

$$\tilde{p}_t^{(k)} = \sum_{m=-\lfloor w/2 \rfloor}^{\lfloor w/2 \rfloor} c_m \cdot p_{t+m}^{(k)}$$

dove i coefficienti c_m sono determinati proprio dalla regressione polinomiale locale all'interno della finestra.

Nella nostra configurazione abbiamo scelto di impostare l'ampiezza della finestra a $w = 9$ frame, equivalenti a circa 300 ms a 30 fps, utilizzando un polinomio di secondo grado ($d = 2$). L'operazione viene eseguita in modo indipendente su ciascuno dei tre canali di rotazione, ovvero *pitch*, *yaw* e *roll*, lungo l'intero asse temporale. Questo passaggio avviene tramite il modulo `data_loader.py` durante il pre-processamento iniziale. Inoltre, la pulizia del segnale viene effettuata sull'intero dataset prima di procedere con la suddivisione in addestramento, validazione e test, affinché le sequenze di posa di tutti e tre i sottoinsiemi risultino uniformemente filtrate e coerenti tra loro.

Gestione di Sequenze a Lunghezza Variabile: `collate_fn`

Le sequenze audio e di posa nel dataset hanno durate variabili, dipendenti dalla lunghezza delle frasi pronunciate. Poiché PyTorch richiede che i tensori all'interno di un batch abbiano dimensioni uniformi, si è implementata una `collate_fn` all'interno del `DataLoader`; la funzione riceve la lista di campioni del batch e restituisce tensori uniformemente dimensionati tramite *zero-padding*.

Dato un batch $\mathcal{B} = \{(\mathbf{a}^{(i)}, \mathbf{P}^{(i)})\}_{i=1}^B$ con sequenze audio di lunghezze $\{T_{a,i}\}$ e sequenze di posa di lunghezze $\{T_{p,i}\}$, la `collate_fn`:

1. Calcola le lunghezze massime $T_a^{\max} = \max_i T_{a,i}$ e $T_p^{\max} = \max_i T_{p,i}$;
2. Estende ciascuna sequenza audio con zeri a destra fino a $T_a^{\max}$, ottenendo il tensore $\mathbf{A} \in \mathbb{R}^{B \times T_a^{\max}}$;
3. Estende ciascuna sequenza di posa con zeri a destra fino a $T_p^{\max}$, ottenendo il tensore $\mathbf{P} \in \mathbb{R}^{B \times T_p^{\max} \times 3}$;
4. Restituisce i vettori delle lunghezze reali $\ell_p \in \mathbb{Z}^B$ e $\ell_a \in \mathbb{Z}^B$.

Il vettore ℓ_p viene passato sia al modello (per determinare la lunghezza di interpolazione nel *forward pass*) sia alla funzione di errore (per costruire la maschera $\mathcal{M}$ descritta nella Sezione 3.1.3), garantendo che i frame padding non contribuiscano né alla predizione né alla stima del gradiente.

Caching del Dataset

Il pre-processamento del dataset, che include il caricamento audio tramite `librosa`, la normalizzazione tramite `Wav2Vec2Processor` e l'applicazione del filtro Savitzky-Golay, richiede un tempo computazionale significativo al primo avvio. Per ottimizzare i tempi nelle run successive, i dati pre-processati

vengono serializzati su disco in un file di cache (`s2p_cache.pkl`) tramite il modulo `pickle` di Python. Nei run successivi, in presenza del file di cache, il dataset viene caricato direttamente dalla struttura serializzata, saltando integralmente la fase di pre-processamento.

Capitolo 4

Esperimenti

Il presente capitolo descrive il percorso sperimentale seguito per l’addestramento e la valutazione del modulo **SpeechToPose**. Inizialmente, il sistema presentava gravi difetti e non produceva animazioni plausibili. L’esposizione, pertanto, rappresenterà una vera e propria cronologia dell’evoluzione progressiva della pipeline di addestramento. Gli esperimenti raccontano la ricerca iterativa di risultati positivi: col passare del tempo, sono state apportate modifiche al codice per ottenere risultati migliori, e i difetti via via osservati hanno guidato le scelte metodologiche successive.

Ogni esperimento è presentato secondo una struttura, costituita da motivazione iniziale, dettaglio delle modifiche rispetto alle prove precedenti e analisi critica dei risultati ottenuti.

4.0.1 Setup Sperimentale

Gli esperimenti sono stati condotti su un server del Media Integration and Communication Center (MICC) dell’Università di Firenze. Il training è stato monitorato in tempo reale tramite la piattaforma *Comet ML*, che ha

permesso di tracciare le curve di loss, gli iperparametri e i tempi di esecuzione per ogni run.

Dati. Il dataset è quello derivato da MEAD e pre-processato tramite EMO-TE [3, 13], descritto in dettaglio nella Sezione 3.2. La cartella **audio** contiene i segnali di parlato usati come input, mentre la cartella **pose** contiene le corrispondenti sequenze di angoli di posa (*pitch*, *yaw*, *roll*) usate come target di supervisione.

La **valutazione quantitativa** si basa sull'osservazione dei grafici di Train Loss e Validation Loss per diagnosticare la stabilità dell'addestramento, affiancata dall'estrazione di metriche oggettive calcolate sull'intero test set. Per formalizzare le grandezze in esame, si definiscano N come il numero totale di fotogrammi, $\theta_t, \hat{\theta}_t \in \mathbb{R}^3$ come i vettori di posa (predetti e reali) al tempo t , e $V_{t,v}, \hat{V}_{t,v} \in \mathbb{R}^3$ come le coordinate spaziali del v -esimo vertice (con $N_v = 5023$) del modello FLAME. Le metriche misurate sono quattro:

- **PosLoss Angolare:** calcolata come errore medio assoluto (MAE) in gradi per i tre assi di rotazione (*Pitch*, *Yaw*, *Roll*). È formulata come:

$$\text{MAE}_{\text{ang}} = \frac{1}{3N} \sum_{t=1}^N \sum_{c=1}^3 |\theta_{t,c} - \hat{\theta}_{t,c}|$$

- **VelLoss Angolare (Temporal Consistency):** misurata in rad/frame per valutare la coerenza temporale del movimento. Definendo la derivata temporale discreta $\Delta\theta_t = \theta_t - \theta_{t-1}$, il MAE angolare temporale si esprime come:

$$\text{VelMAE}_{\text{ang}} = \frac{1}{3(N-1)} \sum_{t=2}^N \sum_{c=1}^3 |\Delta\theta_{t,c} - \Delta\hat{\theta}_{t,c}|$$

- **PosLoss su Mesh 3D FLAME:** esprime il *Mean Vertex Error* (MVE) in millimetri, misurando la distanza spaziale effettiva (Norma L_2 euclidea) tra il volto predetto e la *Ground Truth* tramite l'equazione:

$$\text{MVE} = \frac{1}{N \cdot N_v} \sum_{t=1}^N \sum_{v=1}^{N_v} \|V_{t,v} - \hat{V}_{t,v}\|_2$$

- **VelLoss su Mesh 3D:** quantifica l'errore di velocità direttamente sulla superficie tridimensionale (in m/frame) per identificare l'eventuale instabilità geometrica (*jittering*) durante l'animazione. Definendo $\Delta V_{t,v} = V_{t,v} - V_{t-1,v}$ e valutando ogni coordinata $d \in \{x, y, z\}$, l'errore è calcolato come:

$$\text{VelMAE}_{\text{mesh}} = \frac{1}{3N_v(N-1)} \sum_{t=2}^N \sum_{v=1}^{N_v} \sum_{d=1}^3 |\Delta V_{t,v,d} - \Delta \hat{V}_{t,v,d}|$$

La **valutazione qualitativa** si fonda sulla generazione di video comparativi progettati per esaminare visivamente la naturalezza del movimento e la sua corrispondenza con l'audio. I vertici generati fornendo la traccia acustica in input al modulo **SpeechToPose** (abbinato al preesistente **ScanTalk**) vengono renderizzati e affiancati direttamente ai vertici della pseudo-*Ground Truth*. Per documentare questa analisi all'interno dell'elaborato scritto, le sequenze video sono state campionate e organizzate in griglie comparative, le quali espongono i fotogrammi estratti a intervalli regolari permettendo un riscontro visivo immediato della postura della testa e della sua evoluzione temporale.

Iperparametri comuni e Schedule del Learning Rate. Salvo diversa indicazione, gli esperimenti condividono l'uso dell'ottimizzatore Adam. Nei primi esperimenti si è utilizzato un learning rate iniziale $\eta = 10^{-4}$ abbinato a uno scheduler **ReduceLROnPlateau**, nell'intento di mitigare la forte instabilità

della validation loss e forzarne la discesa. Tuttavia, riscontrando che tale riduzione non sortiva l'effetto sperato, negli esperimenti successivi (da EXP4 in avanti) lo scheduler è stato rimosso, mantenendo il learning rate fisso a 10^{-4} . Ai fini della valutazione e del rendering dei video si sono sempre utilizzati i pesi del modello salvati all'ultima epoca disponibile di ciascun esperimento.

4.1 Primi addestramenti (EXP1 e EXP2)

I primissimi tentativi di addestramento (EXP1 e EXP2) sono stati eseguiti su durate limitate (rispettivamente 20 e 50 epoche) e includevano già un termine di *velocity loss* aggiuntivo per regolarizzare il movimento. Tuttavia, i risultati si sono rivelati del tutto insoddisfacenti: la curva di validation loss non mostrava una discesa stabile ma continue oscillazioni, e dal punto di vista visivo il modello manifestava due problemi evidenti e contrapposti. Da un lato la testa si muoveva pochissimo, restando sostanzialmente ferma al centro; dall'altro, in quegli impercettibili movimenti generati, il modello presentava un fenomeno di *jittering* (vibrazioni e scatti innaturali tra frame consecutivi). Gli esperimenti successivi, a partire da EXP3, nascono proprio dalla necessità di diagnosticare e correggere questa problematica.

4.2 EXP3 – Analisi dell'Impatto della Velocity Loss

Motivazione

Poiché i primissimi tentativi mostravano contemporaneamente staticità e scatti improvvisi, in EXP3 si è voluto indagare in dettaglio l'impatto della

velocity loss, già presente nella pipeline fin dalle prime iterazioni. L’obiettivo primario del suo utilizzo e di questo studio è quello di tentare di eliminare il *jittering* e gli scatti tra frame consecutivi, andando ad analizzare la derivata temporale tra due pose adiacenti.

Parallelamente, per verificare se l’assenza di convergenza della validation loss fosse dovuta a un training troppo breve o a un learning rate inadeguato, in questo esperimento si è scelto di estendere il training a 140 epoche e si è introdotto lo scheduler `ReduceLROnPlateau`, con lo scopo di abbassare il learning rate dopo che la validation loss non scendeva per una serie di epoche consecutive.

Configurazione

Sono stati lanciati quattro esperimenti in parallelo, variando esclusivamente il peso λ_{vel} della velocity loss, con valori $\lambda_{\text{vel}} \in \{0, 0.5, 1, 2\}$. Il valore $\lambda_{\text{vel}} = 0$ corrisponde all’esclusione totale della regolarizzazione temporale. L’ottimizzatore sfrutta lo scheduler `ReduceLROnPlateau` ed il limite massimo di epoche è fissato a 140.

Risultati




Figura 4.1: Curve di training loss (pannello sinistro) e validation loss (pannello destro) per le quattro configurazioni di EXP3, al variare del peso $\lambda_{\text{vel}} \in \{0, 0.5, 1, 2\}$. Le stelle indicano le epoche corrispondenti alla validation loss minore.

L'analisi delle curve in Figura 4.1 rivela un andamento comune a tutte le varianti: la validation loss raggiunge il suo valore minimo nelle primissime epoche e successivamente risale. Si potrebbe erroneamente dedurre che il modello, andando in overfitting, stia almeno imparando perfettamente il training set; tuttavia, i render visivi dimostrano il contrario (la rete non riesce a riprodurre i movimenti attesi nemmeno sui dati di addestramento). Ne consegue che il semplice andamento della validation loss in questo contesto non implica affatto che il modello stia funzionando in modo corretto in fase di training. Inoltre, l'introduzione di un peso crescente per la velocity loss non produce alcun miglioramento numerico né visivo.




Figura 4.2: Confronto qualitativo frame-by-frame tra la *Ground Truth* (prima riga) e le predizioni prodotte dalle quattro varianti di EXP3 sulla sequenza di test M003_contempt: $\lambda_{\text{vel}} = 0$ (seconda riga), $\lambda_{\text{vel}} = 0.5$ (terza riga), $\lambda_{\text{vel}} = 1$ (quarta riga), e $\lambda_{\text{vel}} = 2$ (quinta riga). Le colonne corrispondono agli istanti $t \in \{0.0, 0.5, 1.0, 1.5, 2.0\}$ secondi. In tutte le varianti, il modello produce movimenti di ampiezza sensibilmente inferiore rispetto alla Ground Truth, con la testa che rimane sostanzialmente ferma per l'intera durata della sequenza.

L'analisi qualitativa in Figura 4.2 e la visione diretta delle sequenze animate confermano le gravi limitazioni evidenziate dalle curve di loss. In tutte le varianti le teste generate rimangono in posizione pressoché statica per l'intera durata, e soprattutto continuano a soffrire di jittering indipendente-

mente dal valore di λ_{vel} . Questo evidente tremore ad alta frequenza accompagna movimenti nettamente inferiori rispetto alla Ground Truth: la testa del soggetto reale compie rotazioni ampie, mentre le predizioni si limitano a micro-vibrazioni. Questo comportamento è riconducibile al fenomeno di *regression to the mean* documentato nella letteratura per i task di predizione di sequenze motorie da segnali audio [7]: in assenza di un segnale di supervisione sufficientemente discriminativo, il modello apprende a predire valori medi della distribuzione, che minimizzano la loss attesa ma producono movimenti statici e innaturali.

4.3 EXP4 – Standardizzazione della Velocity Loss

Motivazione

L’analisi di EXP3 ha evidenziato un’ulteriore criticità nella pipeline: la procedura di pre-processing dell’audio prevedeva un taglio manuale del segnale per adattarne la lunghezza al numero di frame target. Questa operazione, implementata come `int(n_target_frames / fps × sr)`, introduceva un disallineamento sistematico tra la lunghezza della sequenza audio e il numero di frame predetti, con effetti potenzialmente negativi sull’allineamento temporale tra audio e posa.

A seguito dell’analisi sul *jittering* condotta nell’esperimento precedente si è deciso di testare una nuova formulazione della penalità sulla velocità implementandola in modo standardizzato. Il contributo dinamico è stato infatti normalizzato tenendo conto della scala numerica dell’errore di posizione garantendo così un peso equivalente ai due termini durante la fase di

ottimizzazione.

Configurazione

La modifica principale di EXP4 consiste nel passare l’audio grezzo direttamente all’encoder Wav2Vec 2.0 [1], delegando interamente a quest’ultimo il compito di determinare la lunghezza della sequenza di *feature* estratte. Il campionamento è eseguito a 16 kHz, in linea con le specifiche del modello pre-addestrato. I pesi del modello Wav2Vec 2.0 sono stati completamente congelati (*full freeze*) durante questo round di esperimenti. Inoltre, prendendo atto dei fallimenti dello scheduler nel favorire una convergenza stabile, si è rimosso il `ReduceLROnPlateau`, mantenendo un learning rate rigorosamente fisso a 10^{-4} . Sono stati lanciati due esperimenti in parallelo:

- EXP4-A: $\lambda_{\text{vel}} = 0$ (senza regolarizzazione temporale).
- EXP4-B: λ_{vel} standardizzata rispetto alla MSE loss.

Risultati

I risultati quantitativi di Figura 4.3 mostrano che EXP4-A ($\lambda_{\text{vel}} = 0$) raggiunge una validation loss di 0.00708, lievemente inferiore rispetto al miglior risultato di EXP3 (0.00750, $\lambda_{\text{vel}} = 0.5$). Questo miglioramento è attribuibile alla rimozione del disallineamento temporale introdotto dal taglio manuale dell’audio.




Figura 4.3: Curve di training loss (pannello sinistro) e validation loss (pannello destro) per EXP4-A ($\lambda_{\text{vel}} = 0$, audio grezzo, encoder congelato) e EXP4-B (velocity loss standardizzata, stessa configurazione audio). Le stelle indicano le epoche corrispondenti alla validation loss minore. Si noti la differenza di scala tra i due pannelli: l'introduzione della velocity loss standardizzata aumenta significativamente la magnitudine della loss complessiva.



Figura 4.4: Confronto qualitativo frame-by-frame tra la *Ground Truth* (prima riga), EXP4-B (seconda riga) ed EXP4-A (terza riga).

L'analisi qualitativa di Figura 4.4 mostra che entrambe le varianti pro-

ducono movimenti di ampiezza notevolmente ridotta rispetto alla Ground Truth, pur con un lieve miglioramento nella fluidità della traiettoria per EXP4-B rispetto alle predizioni di EXP3. Tuttavia, il passaggio all’audio grezzo e il congelamento dell’encoder non risolvono il problema fondamentale della staticità, e la testa generata rimane sostanzialmente ferma.

I risultati quantitativi aggregati sull’intero test set di Mead-EMOTE (Tabella 4.1) confermano questa valutazione: EXP4-A ottiene un MAE totale di 4.36° e un MVE di 9.77 mm, risultando complessivamente superiore a EXP4-B (4.64° , 10.27 mm). Applicando la standardizzazione della velocity loss, la rete non beneficia di alcun vantaggio sulle metriche angolari, confermando che la regolarizzazione tramite velocity loss non porta i miglioramenti sperati.

Configurazione	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP4-A ($\lambda_{vel} = 0$)	7.14°	3.57°	2.37°	4.36°	9.77	0.0026	0.00017
EXP4-B (λ_{vel} std)	7.15°	4.08°	2.69°	4.64°	10.27	0.0034	0.00022

Tabella 4.1: Metriche quantitative per EXP4 sul test set aggregato di Mead-EMOTE (2.062 campioni, media pesata per frame).

4.4 EXP5 – Filtro Savitzky-Golay e Tuning dell’Architettura LSTM

Motivazione e Obiettivo

I risultati dei primi esperimenti hanno indicato che il *jittering* e la scarsa ampiezza del movimento non sono eliminabili agendo unicamente sul pre-processing dell’audio. Si è quindi deciso di esplorare sistematicamente l’effetto della profondità della rete LSTM (da 2 a 4 layer) e della larghezza dell’hidden state ($H = 256$ vs $H = 512$) sulla qualità delle predizioni, mantenendo invariati gli altri iperparametri. L’obiettivo è determinare se un’architettura più profonda (per catturare pattern temporali complessi) o più

larga (maggiore capacità rappresentativa) possa mitigare il problema della staticità e migliorare l'aderenza al *Ground Truth*.

Filtro Savitzky-Golay. Per attenuare il rumore ad alta frequenza nei dati di training, si è applicato un filtro passa-basso di tipo Savitzky-Golay [8] alle sequenze target nel `data_loader` (finestra $w = 9$, grado $d = 2$ a 30 FPS). Questo *smoothing* attenua le vibrazioni veloci preservando l'andamento macroscopico.

Custom `collate_fn` e aumento del batch size. Per migliorare la stabilità, il *batch size* è stato impostato a 4. Poiché le sequenze audio hanno durata variabile, è stata implementata una `collate_fn` con *zero-padding* dinamico per consentire a PyTorch di concatenare correttamente tensori di lunghezza diversa.

Configurazione e Varianti

La configurazione comune per questo ciclo di esperimenti prevede l'uso dell'encoder *Wav2Vec2-base-960h* (frozen), ottimizzatore Adam con learning rate fisso a 10^{-4} (senza scheduler), dropout a 0.1 e velocity loss disabilitata ($\lambda_{\text{vel}} = 0.0$) per isolare l'impatto architetturale. Sono stati definiti quattro esperimenti, le cui specifiche architetturali sono riassunte in Tabella 4.2:

Esperimento	Layer (L)	Hidden (H)	Parametri	Obiettivo
EXP5-1	2	256	$\sim 98\text{M}$	Baseline, rete minima.
EXP5-2	3	256	$\sim 98\text{M}$	+1 layer: cattura pattern temporali più complessi.
EXP5-3	4	256	$\sim 98\text{M}$	Massima profondità con $H = 256$.
EXP5-4	3	512	$\sim 149\text{M}$	Larghezza raddoppiata rispetto a EXP5-2.

Tabella 4.2: Configurazioni architetturali valutate in EXP5.

Nota: Il training era inizialmente previsto per 200 epoche con checkpoint ogni 20 epoche. Tuttavia, a causa di valutazioni intermedie, le esecuzioni sono state arrestate anticipatamente (tra le 80 e le 120 epoche). I risultati riportati utilizzano i pesi dell'ultimo checkpoint disponibile per ciascun run.




Figura 4.5: Curve di training loss (pannello sinistro) e validation loss (pannello destro) per le quattro configurazioni LSTM di EXP5. Le stelle indicano le epoche corrispondenti alla validation loss minore.

Valutazione sul Test Set

L'andamento delle curve di apprendimento e validazione è riportato in Figura 4.5. Come per gli esperimenti precedenti, la validation loss tocca il

minimo nelle prime decine di epoche per poi stabilizzarsi. Al fine di misurare l'efficacia reale delle modifiche architettureali, vengono confrontate le metriche aggregate sull'intero test set di Mead-EMOTE (2.062 campioni), valutando congiuntamente l'errore angolare e la deformazione metrica sulla mesh 3D. Se le nuove varianti di EXP5 fossero in grado di estrarre feature temporali migliori, questo si tradurrebbe in una maggiore fedeltà ai movimenti su soggetti mai visti in training.

Configurazione	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP5-1 (2L, h=256)	7.16°	3.74°	2.56°	4.49°	9.96	0.0041	0.00026
EXP5-2 (3L, h=256)	7.31°	4.16°	2.61°	4.69°	10.39	0.0030	0.00019
EXP5-3 (4L, h=256)	6.93°	3.78°	2.61°	4.44°	9.86	0.0028	0.00018
EXP5-4 (3L, h=512)	7.86°	4.00°	2.68°	4.85°	10.79	0.0031	0.00021

Tabella 4.3: Metriche quantitative per EXP5 sul test set aggregato di Mead-EMOTE (2.062 campioni, media pesata per frame).




Figura 4.6: Confronto qualitativo su sequenza di **Test**. Riga superiore: GT. Righe successive: EXP5-1, EXP5-2, EXP5-3, EXP5-4.

Come emerge dai dati numerici (Tabella 4.3) e dal riscontro visivo (Figura 4.6), sebbene la configurazione EXP5-3 registri il MAE totale più contenuto (4.44°) tra le quattro varianti, il modello mostra evidenti limiti sui dati di test. Ciascuna configurazione produce infatti animazioni pressoché statiche, incapaci di riprodurre la naturale dinamica del Ground Truth. L’analisi qualitativa conferma come l’approccio deterministico, pur aumentando la complessità della rete, ricada nel fenomeno della *regression to the mean*, impedendo al sistema di generalizzare movimenti del capo realistici.

Valutazione sul Train Set e Discussione

Constatando che i modelli fallivano completamente sui dati di test nonostante l’aumentata capacità architetture, si è rivelato necessario fare un passo indietro: ci siamo chiesti se il modello fosse riuscito almeno a memorizzare le traiettorie dei dati su cui si era allenato. Per scoprirlo, si è passati a valutare quantitativamente e qualitativamente le stesse configurazioni direttamente su un campione del **Train set** (Tabella 4.4 e Figura 4.7).

Configurazione	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP5-1 (2L, h=256)	5.29°	4.85°	9.42°	6.52°	13.52	0.0114	0.0007
EXP5-2 (3L, h=256)	8.45°	5.06°	8.50°	7.34°	15.19	0.0107	0.0006
EXP5-3 (4L, h=256)	9.18°	4.18°	6.46°	6.61°	13.93	0.0099	0.0006
EXP5-4 (3L, h=512)	7.83°	4.57°	8.52°	6.97°	14.62	0.0103	0.0006

Tabella 4.4: Metriche quantitative per EXP5 sul campione di **Train** (M003).




Figura 4.7: Confronto qualitativo su sequenza di **Train** (file: M003_contempt). Riga superiore: Ground Truth. Righe successive: LSTM 3L h=256, LSTM 4L h=256, LSTM 3L h=512.

Il risultato di questa analisi è sorprendente e allarmante: come illustrato nella Figura 4.7, non funziona neanche per un campione del train set. L'ispezione qualitativa dimostra che le quattro varianti LSTM restituiscono ancora predizioni statiche e non replicano i naturali scuotimenti o rotazioni della testa visibili nella Ground Truth, fallendo non solo in fase di test, ma perfino sui dati esatti utilizzati per calcolare il gradiente di loss.

Questa rivelazione ha suggerito un problema strutturale molto più profondo della "semplice" incapacità di generalizzazione: forse la pipeline di addestramento fin qui costruita imponeva un ostacolo invisibile che bloccava la memorizzazione alla base. Da questa constatazione è nato il successivo esperimento (EXP6).

4.5 EXP6 – Overfitting Intenzionale

Motivazione

Gli esperimenti precedenti, in particolare EXP5, hanno evidenziato un comportamento critico: il modello non soltanto fatica a generalizzare sui dati di test, ma produce traiettorie quasi statiche perfino sui dati di addestramento. Questo risultato ha sollevato dubbi sia sull'architettura adottata sia sull'idoneità del dataset, dato che Mead-EMOTE non è stato originariamente concepito per la predizione dei movimenti del capo. Ci si è quindi concentrati sulla prima ipotesi, per comprendere se la rete fosse strutturalmente incapace di memorizzare sequenze motorie complesse.

Per fare chiarezza su questo punto, in EXP6 si è adottata una strategia di overfitting intenzionale: addestrare il modello per un numero elevato di epoche (fino a 300), con l'obiettivo mirato di verificare se la rete riuscisse ad apprendere e riprodurre fedelmente le traiettorie di training. L'eventuale incapacità di riprodurre i movimenti anche in una condizione così favorevole alla memorizzazione avrebbe dimostrato in modo inequivocabile i limiti dell'architettura proposta.

Configurazione

Sono stati lanciati quattro esperimenti in parallelo per investigare la convergenza sotto overfitting puro, le cui impostazioni sono riportate in Tabella 4.5:

Config.	Layer (L)	Hidden (H)	λ_{vel}	Note
EXP6-A	4	512	0	Architettura più capace, no vel loss
EXP6-B	3	512	0	Architettura intermedia, no vel loss
EXP6-C	4	512	2	Architettura più capace, vel loss attiva ($\lambda_{\text{vel}} = 2$)
EXP6-D	4	512	0	Learning rate aumentato a 10^{-3}

Tabella 4.5: Configurazioni architetturali e parametri di training per EXP6. In tutti gli esperimenti il training è condotto su 300 campioni per 300 epoche.




Figura 4.8: Andamento della MSE Loss (Training a sinistra, Validation a destra) per i quattro modelli confrontati in EXP6. Si nota la rapida discesa dovuta all'overfitting intenzionale su dataset ridotto.

Valutazione sul Test Set

L'andamento della funzione di costo è illustrato in Figura 4.8, dove si apprezza la ripida discesa dovuta all'addestramento su dataset compatto. Seguendo lo stesso flusso metodologico, si valutano le prestazioni sull'intero test set aggregato di Mead-EMOTE (Tabella 4.6). Bisogna sottolineare come

la valutazione su test, in questo esperimento orientato all’overfitting controllato, sia condotta essenzialmente per completezza documentale; non essendo questo l’obiettivo della rete in questa fase, dal test set non ci si attende infatti alcuna reale capacità di generalizzazione.

Config.	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP6-A	7.21°	3.71°	2.58°	4.50°	10.02	0.0065	0.00041
EXP6-B	7.25°	3.85°	2.59°	4.56°	10.15	0.0076	0.00048
EXP6-C	7.31°	4.01°	2.82°	4.71°	10.43	0.0028	0.00018
EXP6-D	6.72°	3.31°	2.43°	4.16°	9.35	0.0046	0.00030

Tabella 4.6: Metriche quantitative per EXP6 sul test set aggregato di Mead-EMOTE (2.062 campioni, media pesata per frame).

Come confermato dai numeri e palesemente visibile in Figura 4.9, il modello su dati di test continua a restituire animazioni piatte, frontali e innaturali, incapaci di cogliere alcun elemento dinamico o generalizzante. L’indagine si sposta quindi sulla memorizzazione pura, ovvero sul Train.

Valutazione sul Train Set

Arrivando finalmente al nucleo dell’esperimento, si valuta la resa della rete sullo stesso esatto set ridotto di 300 campioni sui quali è stata iterata ininterrottamente. In questo caso, le aspettative visive sono molto più severe. I risultati numerici sono riportati in Tabella 4.7.

Config.	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP6-A	3.00°	4.24°	7.42°	4.89°	10.57	0.0140	0.0009
EXP6-B	5.36°	3.98°	7.40°	5.58°	11.60	0.0138	0.0009
EXP6-C	1.15°	0.80°	0.82°	0.92°	1.98	0.0067	0.0004
EXP6-D	6.38°	4.68°	9.28°	6.78°	14.12	0.0110	0.0007

Tabella 4.7: Metriche quantitative per EXP6 sul campione di training set (M003_contempt_2_022, 82 frame).




Figura 4.9: Confronto qualitativo frame-by-frame per EXP6 sul campione del test set (W037_disgusted_3_003).




Figura 4.10: Confronto qualitativo frame-by-frame per EXP6 sul campione del training set (M003_contempt_2_022). La prima riga mostra la Ground Truth. Le righe successive riportano le predizioni prodotte da EXP6-A, EXP6-B, EXP6-C ed EXP6-D.

Dall’analisi qualitativa sul Train emerge un risultato importante per la nostra indagine: mentre i modelli EXP6-A, EXP6-B e EXP6-D (indipendentemente dall’enorme capacità e dal learning rate elevato) restituiscono pose ancora sostanzialmente piatte e deludenti, solamente con EXP6-C si riesce a replicare correttamente i movimenti della testa.

Come emerge dai render in Figura 4.10 la variante C permette alla testa di recuperare un’adeguata ampiezza di rotazione e una fluidità naturale. Il

movimento generato si allinea fedelmente alla sequenza reale accompagnando il segnale audio in modo coerente. I valori di errore estremamente ridotti registrati in questa configurazione forniscono una solida validazione numerica per l'elevata fedeltà visiva raggiunta dal modello.

Analisi e Discussione

I risultati dell'esperimento EXP6 dimostrano che la rete è in grado di trasformare il segnale audio in rotazioni fluide della testa, superando finalmente il problema dell'immobilità (il cosiddetto "collasso verso la media"). Tuttavia, questo traguardo si raggiunge solo forzando il modello a imparare i dati a memoria (in forte overfitting) attraverso l'uso mirato della Velocity Loss. Aumentando il peso di questa funzione ($\lambda_{\text{vel}} = 2$), il sistema è stato costretto a calcolare la differenza di movimento tra fotogrammi consecutivi, ottenendo così la fluidità visiva necessaria per riprodurre fedelmente le pose di addestramento. Nonostante questo successo strutturale la generalizzazione resta un ostacolo insuperabile e il modello crolla inevitabilmente sui dati non visti. Si ipotizza che questa incapacità derivi direttamente dalla scarsa qualità di Mead-EMOTE le cui pose presentano limitazioni tecniche e una rumorosità di fondo capaci di compromettere l'apprendimento di una mappatura robusta.

4.6 EXP7 – Adozione del Dataset HDTF-TFHP

Per rispondere a questo interrogativo e validare il modello su un compito reale il settimo ciclo di esperimenti abbandona la precedente base di dati in favore di HDTF-TFHP. Questo corpus rappresenta l'esatto bench-

mark di riferimento utilizzato da architetture recenti di grande successo come DiffPoseTalk [11].

L'adozione di questa risorsa permette di eliminare alla radice il rumore di estrazione garantendo un addestramento su rotazioni ampie e naturali. Questa transizione offre finalmente un banco di prova ideale per verificare in modo definitivo se un segnale visivo di alta qualità sia sufficiente a far generalizzare l'architettura deterministica su soggetti mai visti.

Il Dataset HDTF-TFHP

Il corpus comprende 1052 video di 588 soggetti differenti raccolti da lezioni accademiche, corsi online, interviste e telegiornali. Questa eterogeneità di contenuti garantisce una notevole varietà negli stili oratori e nei movimenti naturali della testa. Tutti i video sono stati standardizzati a un frame rate di 25 fps permettendo l'estrazione di oltre due milioni di fotogrammi completi dei rispettivi parametri spaziali FLAME.

Il dataset è stato preventivamente elaborato dal Dr. Nocentini per risultare strutturalmente identico al formato impiegato per Mead-EMOTE garantendo una perfetta compatibilità con il codice sorgente già sviluppato. Per scongiurare qualsiasi rischio di contaminazione dei dati tra le fasi di addestramento e valutazione è stata inoltre implementata una rigorosa suddivisione formale dei campioni.

Come evidenziato dal confronto statistico in Tabella 4.8 la differenza strutturale più rilevante tra i due domini riguarda la durata delle sequenze. Pur presentando un numero complessivo di clip nettamente inferiore HDTF-TFHP offre tracce di lunghezza significativamente maggiore garantendo una stabilità temporale fondamentale per l'apprendimento delle dinamiche a lungo termine. La durata mediana delle sequenze passa infatti da soli 4 a ben

58 secondi con i video più lunghi che arrivano a sfiorare gli otto minuti di parlato ininterrotto.

Metrica	Mead-EMOTE	HDTF-TFHP	Rapporto
Numero di sequenze	25.411	1.113	N/A
Sequenza più corta	1,0 s	9,9 s	$\sim 10\times$
25° percentile	3,2 s	45,0 s	$\sim 14\times$
Mediana	4,0 s	58,0 s	$\sim 15\times$
Media	4,3 s	85,0 s	$\sim 20\times$
75° percentile	5,2 s	70,5 s	$\sim 14\times$
90° percentile	6,7 s	227,3 s	$\sim 34\times$
Sequenza più lunga	17,3 s	437,9 s (7,3 min)	$\sim 25\times$
Durata totale	30,53 h	26,27 h	$\sim 0,86\times$

Tabella 4.8: Confronto statistico sulla durata delle sequenze tra Mead-EMOTE e HDTF-TFHP.

Pre-Processing e Modifiche Architettureali (Lazy Loading)

La maggiore estensione temporale delle nuove sequenze ha richiesto una riprogettazione del modulo di caricamento dei dati all'interno dello script `S2P/data_loader.py`. L'approccio originario, basato sul caricamento diretto dell'intero dataset in memoria, si è rivelato incompatibile con i video di lunga durata (fino a 7 minuti), causando immediatamente errori di esaurimento della memoria di sistema (*Out Of Memory* - OOM). Anche l'impiego di una memoria cache monolitica è risultato impraticabile a causa dei limiti fisici della RAM a disposizione.

Per superare questa criticità tecnica senza dover scartare porzioni di dati o imporre soglie massime di durata, è stata implementata una strategia ibrida basata sul partizionamento su disco (*Disk Chunking*) e sul caricamen-

to ritardato (*Lazy Loading*). In una prima fase di esplorazione del dataset (`read_data`), i video e le relative *feature* audio che superano un certo limite temporale vengono segmentati automaticamente in blocchi gestibili della durata esatta di 20 secondi (`chunk_seconds = 20`). Questi frammenti non vengono mantenuti in RAM, ma vengono salvati fisicamente all'interno di una directory temporanea locale denominata `dataset_chunks`.

Conseguentemente, la classe `PoseDataset` di PyTorch è stata riscritta affinché, durante l'inizializzazione, conservi in memoria esclusivamente i percorsi (*path*) ai file temporanei. I tensori effettivi (`audio_features` e `pose_target`) vengono letti dal disco e trasferiti in RAM esplicitamente solo al momento della chiamata al metodo `__getitem__` (*Lazy Evaluation*). Questa architettura ha permesso di ridurre di ordini di grandezza l'occupazione di memoria dell'applicativo.

Infine, per rispettare le partizioni precalcolate fornite dal Dr. Nocentini, la logica del *dataloader* è stata ulteriormente raffinata. Il sistema rileva automaticamente la presenza della cartella `splits/` e analizza a quale video d'origine appartiene ciascun frammento da 20 secondi (riconducendo, ad esempio, l'identificativo `base_key_chunkN` a `base_key`). Questo meccanismo assicura che tutti i segmenti derivati da un medesimo oratore ricadano esclusivamente all'interno dello stesso *split* (Train, Validation o Test), prevenendo efficacemente qualsiasi rischio di *data leakage*.

Valutazione Quantitativa




Figura 4.11: Curve di addestramento e validazione per il settimo esperimento. La stella indica l'epoca corrispondente al minimo raggiunto prima dell'innesco del fenomeno di overfitting.

L'analisi dei grafici di addestramento in Figura 4.11 conferma che la maggiore regolarità temporale del nuovo dataset ha permesso alla rete di evitare le improvvise divergenze numeriche riscontrate nei tentativi esplorativi precedenti. Il modello riesce finalmente a convergere ma il miglior risultato in validazione viene registrato in modo precoce già all'epoca 26. Da quel momento la funzione di costo intraprende una inesorabile risalita che certifica l'insorgere del fenomeno di overfitting. Questa dinamica dimostra che l'adozione di un corpus esteso e variegato non basta da sola a garantire la generalizzazione su dati non visti.

Modello	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP7 (Epoca 200)	4.46°	5.18°	3.99°	4.54°	22.57	0.0043	0.00072

Tabella 4.9: Metriche quantitative per l'Esperimento 7 sul test set aggregato di HDTF-TFHP.

In linea con la rigorosa politica valutativa adottata i risultati quantitativi riportati in Tabella 4.9 si riferiscono ai pesi estratti al termine dell’addestramento anziché al miglior checkpoint. Questa scelta evidenzia come il prolungato overfitting non produca alcun vantaggio in fase di inferenza. L’analisi aggregata sul test set riflette in pieno i limiti strutturali del modello. Nonostante l’indiscutibile salto di qualità dei dati in ingresso non si assiste al miglioramento prestazionale auspicato. L’errore angolare globale e lo scostamento metrico sui vertici restano infatti ancorati a valori insoddisfacenti confermando l’assoluta incapacità dell’architettura deterministica di generare movimenti plausibili su soggetti sconosciuti.

Valutazione Qualitativa e Discussione




Figura 4.12: Confronto qualitativo su un frammento estratto dal dataset HDTF-TFHP. In alto la Ground Truth e in basso la predizione generata nell’esperimento EXP7 caratterizzata da una marcata staticità rispetto al naturale dinamismo dell’originale.

L’esito deludente dell’analisi quantitativa trova un riscontro visivo inequivocabile nella Figura 4.12. Il volto predetto si stabilizza infatti in una posa neutra e centrale perdendo del tutto le oscillazioni e i naturali annuimenti

presenti nel video di riferimento. Questa marcata immobilità rappresenta la classica manifestazione visiva del collasso verso la media.

4.7 EXP8 – Il modello Variational Autoencoder

L’obiettivo di questo ottavo esperimento è sostituire la rigida mappatura deterministica con un approccio probabilistico in grado di generare molteplici movimenti validi a partire dallo stesso input vocale.

Motivazioni e Architettura

Nel mondo reale l’interazione tra voce e movimento del capo rappresenta un classico problema *one-to-many*. Pronunciando la stessa frase un oratore può compiere rotazioni della testa completamente diverse o restare fermo. Addestrando una rete tradizionale con l’Errore Quadratico Medio il modello viene severamente penalizzato ogni volta che tenta una traiettoria diversa da quella dell’unico video di riferimento pur trattandosi di un movimento plausibile. Per minimizzare i rischi l’architettura converge inevitabilmente verso la media statistica del dataset che corrisponde di fatto a un volto del tutto immobile.

Per superare questo limite strutturale l’architettura si evolve adottando un Variational Autoencoder. Anziché forzare il sistema a stimare un’unica posa esatta il modello apprende una distribuzione di probabilità governata da uno spazio latente stocastico che modella lo stile globale del movimento. Durante l’addestramento un codificatore ricorrente analizza la posa reale ed estrae le caratteristiche dinamiche della sequenza restituendo i pa-

rametri statistici di una distribuzione Gaussiana anziché un singolo vettore deterministico.

Configurazione

Durante l'addestramento il codificatore delle pose analizza l'intera sequenza reale condensandone le caratteristiche stilistiche globali per ricavare i parametri di una distribuzione gaussiana. Da questa distribuzione viene campionato un vettore stocastico di stile a 64 dimensioni sfruttando il trucco di riparametrizzazione per garantire la piena differenziabilità della rete.

Il vettore latente così ottenuto viene concatenato istante per istante con le caratteristiche acustiche estratte dal modulo audio. Il segnale congiunto viene quindi fornito in ingresso al decodificatore ricorrente incaricato di fondere il condizionamento vocale e lo stile stocastico per generare la sequenza temporale delle pose predette.

Per guidare efficacemente l'apprendimento la funzione di ottimizzazione affianca al classico errore di ricostruzione spaziale e temporale una penalità probabilistica basata sulla divergenza di Kullback-Leibler. Al fine di prevenire il collasso della distribuzione latente il peso di questa divergenza viene incrementato in modo lineare durante le prime dieci epoche di addestramento. Tutti i dettagli dimensionali e gli iperparametri specifici della configurazione sono riassunti in Tabella 4.10.

Parametro / Componente	Specifiche EXP8 (HeadPoseVAE)
Dimensione Spazio Latente (Z)	64
Pose Encoder	LSTM ($L = 1, H = 256$) + Temporal Avg Pooling
Decoder Ricorrente	Bi-LSTM ($L = 3, H = 256$, input dim 832)
Peso Velocità (λ_{vel})	2.0
Peso Divergenza KL (λ_{kld})	0.001
Programma KL Annealing	Lineare su 10 epoche
Ottimizzatore e Learning Rate	AdamW, $\eta = 10^{-4}$
Epoche di Addestramento	200 (batch size 4)
Dataset di Valutazione	HDTF-TFHP (chunk da 499 frame)

Tabella 4.10: Configurazione architetturale e iperparametri per l’ottavo esperimento.

Valutazione Quantitativa




Figura 4.13: Curve di addestramento e validazione per l’ottavo esperimento. La stella indica l’epoca corrispondente al minimo raggiunto in fase di validazione.

I grafici di addestramento in Figura 4.13 descrivono una dinamica di apprendimento stabile pur ricalcando alcune criticità già note. La funzione

di costo in validazione tocca rapidamente il proprio minimo alla seconda epoca per poi intraprendere una risalita graduale.

Modello	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP8 (VAE)	4.47°	5.31°	4.36°	4.71°	22.82	0.0044	0.00073

Tabella 4.11: Metriche quantitative per EXP8 sul test set aggregato di HDTF-TFHP. L’inferenza è stata condotta impostando il vettore latente a zero.

L’analisi quantitativa riportata in Tabella 4.11 delinea un quadro prestazionale del tutto analogo a quello dell’architettura deterministica. L’errore angolare globale e lo scostamento metrico sui vertici risultano persino leggermente superiori a quelli registrati nel settimo esperimento.

Valutazione Qualitativa e Discussione




Figura 4.14: Confronto qualitativo su un frammento estratto per l’ottavo esperimento. In alto la Ground Truth e in basso la predizione del VAE caratterizzata da un’evidente e persistente immobilità.

I dati quantitativi trovano immediato riscontro nell’analisi visiva proposta in Figura 4.14. Il volto generato mantiene infatti una marcata staticità per l’intera durata del frammento confermando che l’introduzione di un’architettura stocastica non è da sola sufficiente ad arginare il noto fenomeno della regressione verso la media.

La causa principale di questo fallimento risiede nel nucleo stesso dell'ottimizzazione. Sebbene il modello sia teoricamente in grado di esplorare stili latenti differenti l'errore di ricostruzione continua a penalizzare severamente qualsiasi scostamento puntuale dal fotogramma di riferimento. Poiché il movimento del capo rappresenta una caratteristica comportamentale slegata dalla rigida articolazione fonetica la rete impara rapidamente a ignorare il parametro stocastico. Per minimizzare la funzione di costo il sistema sceglie sistematicamente la via matematicamente più sicura (la media) annullando del tutto il dinamismo.

4.8 EXP9 – One-Hot Encoding degli Speaker

Motivazione

Il movimento della testa durante il parlato è un fenomeno fortemente soggettivo che varia in modo radicale da persona a persona. L'ipotesi alla base di questo nono esperimento è che la tendenza del modello a convergere verso una posa statica possa essere mitigata fornendo esplicitamente l'identità dell'oratore come informazione ausiliaria, riducendo così l'ambiguità tra il segnale vocale e le molteplici traiettorie presenti nel dataset. L'obiettivo dell'esperimento è quindi verificare se l'integrazione di questa specifica informazione stilistica sia da sola sufficiente per smuovere la testa e sbloccare la generazione del movimento.

Configurazione

Per testare questa ipotesi si è ripresa l'architettura deterministica di base già collaudata nel settimo esperimento. L'unica modifica strutturale introdotta riguarda il condizionamento della rete tramite la codifica *One-*

Hot dell'identità del parlante. A livello implementativo il sistema assegna un'etichetta univoca a ciascuno dei 587 oratori presenti nel dataset.

Durante il passaggio dei dati nella rete questo identificativo viene convertito in un vettore *One-Hot* che viene replicato lungo l'intera dimensione temporale della sequenza e concatenato alle caratteristiche acustiche estratte dal codificatore. Questa operazione espande la dimensione in ingresso al modulo ricorrente da 768 a 1355 elementi.

Valutazione Quantitativa




Figura 4.15: Curve di addestramento e validazione per EXP9. La stella indica l'epoca corrispondente al minimo raggiunto durante la fase di validazione.

Le curve riportate in Figura 4.15 mostrano un andamento che ricalca da vicino le criticità già riscontrate negli esperimenti precedenti. La funzione di costo in validazione raggiunge il proprio minimo in modo estremamente precoce alla seconda epoca per poi risalire progressivamente evidenziando un fenomeno di severo overfitting a fronte di un errore di addestramento in costante discesa. In totale aderenza con la metodologia consolidata nei cicli passati la valutazione sul test set impiega i pesi estratti al termine dell'ultima epoca disponibile.

Modello	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP9 (One-Hot)	4.39°	5.14°	3.98°	4.50°	22.50	0.0045	0.00073

Tabella 4.12: Metriche quantitative per EXP9 sul test set aggregato di HDTF-TFHP.

I dati riportati in Tabella 4.12 certificano che il condizionamento sull'identità mantiene i livelli di errore globali del tutto analoghi alla baseline. L'errore metrico sui vertici migliora in maniera quasi impercettibile rispetto ai tentativi precedenti senza però alterare il quadro generale. I valori legati alla velocità angolare e spaziale risultano infatti rigorosamente identici a quelli passati fornendo la prova inequivocabile che la traiettoria temporale prodotta rimane piatta e priva di variazioni espressive.

Valutazione Qualitativa e Discussione



Figura 4.16: Confronto qualitativo su un frammento estratto da HDTF-TFHP. In alto la Ground Truth e in basso la predizione di EXP9. La testa parte da una posizione inclinata, ma non si muove.

Come emerge dall'osservazione della Figura 4.16 l'aggiunta dell'identità non produce alcun miglioramento visibile. La testa generata mantiene una posizione neutra per l'intera durata del frammento confermando la totale assenza di dinamismo già certificata dai dati numerici.

La mancata efficacia di questo esperimento deriva da due limiti strutturali. In primo luogo la semplice concatenazione del vettore *One-Hot* viene interpretata dalla rete come un banale offset geometrico. Il modello impara a sfruttare questa informazione unicamente per variare la postura di base del singolo soggetto mantenendo piatta la generazione del movimento nel tempo. In secondo luogo conoscere l'identità dell'oratore non risolve l'ambiguità intrinseca del problema. L'ottimizzazione tramite Errore Quadratico Medio si limita semplicemente a ripiegare su una posa media specifica per quel parlante anziché su una media universale producendo un risultato altrettanto statico.

4.9 EXP10 – Il termine di costo FaceLoss

Appurato che l'introduzione dell'identità del parlante non basta a risolvere la staticità delle predizioni l'indagine si sposta su una nuova ipotesi matematica. Il limite del modello potrebbe non risiedere nell'utilizzo dell'Errore Quadratico Medio ma nello spazio geometrico in cui questo viene calcolato.

Ottimizzare direttamente gli angoli di Eulero impone infatti alla rete di minimizzare un errore non uniforme. A parità di ampiezza una rotazione sull'asse *roll* e una sull'asse *yaw* producono spostamenti millimetrici molto diversi nelle varie zone della testa, eppure la metrica angolare li penalizza in modo identico. Seguendo l'approccio di lavori recenti come DiffPoseTalk [11] e SadTalker [16] la funzione di costo viene quindi ricalcolata sulla geometria della mesh tridimensionale.

Configurazione

Pur mantenendo inalterata l'architettura di base la funzione di costo viene interamente riformulata nello spazio tridimensionale della mesh facciale. La novità principale riguarda l'introduzione della FaceLoss in sostituzione della tradizionale PosLoss. Invece di calcolare l'errore sui tre angoli predetti la metrica viene applicata alle coordinate spaziali dei vertici del volto, ottenute ruotando un *template* canonico tramite gli angoli stimati dalla rete.

Parallelamente anche la regolarizzazione temporale viene riadattata trasformandosi in una Mesh Velocity Loss. Questa nuova funzione abbandona il dominio angolare per agire sui vertici 3D tra fotogrammi consecutivi.

Per isolare e valutare esclusivamente il contributo di questa nuova supervisione geometrica il condizionamento sulle identità sperimentato in precedenza viene temporaneamente disabilitato.

Valutazione Quantitativa




Figura 4.17: Curve di addestramento e validazione per EXP10. La stella indica l'epoca corrispondente al minimo raggiunto durante la fase di validazione.

Le curve di addestramento in Figura 4.17 evidenziano un’ottimizzazione priva di divergenze esplosive sebbene la validazione mostri una leggera e continua risalita. Passando alle metriche globali i valori si mantengono su cifre pressoché identiche a quelle delle configurazioni precedenti. Questo riscontro numerico certifica che la rete continua a riprodurre un posizionamento statico schiacciato sulla posa media senza riuscire a generare movimenti significativi.

Modello	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP10 (FaceLoss)	4.49°	5.16°	4.01°	4.55°	22.60	0.0044	0.00073

Tabella 4.13: Metriche quantitative per EXP10 sul test set aggregato di HDTF-TFHP (614 chunk, 283.359 frame totali).

I dati quantitativi in Tabella 4.13 confermano che il decimo esperimento si mantiene su prestazioni del tutto analoghe a quelle delle architetture precedenti. Il confronto diretto con la baseline evidenzia come la FaceLoss apporti variazioni puramente marginali con differenze inferiori al decimo di grado sull’errore angolare e al decimo di millimetro su quello spaziale, risultando a tratti persino inferiore ai risultati del nono esperimento. Anche i parametri di velocità restano sostanzialmente invariati rispetto ai cicli passati offrendo un’ulteriore e definitiva conferma del fatto che la dinamica temporale risulta ancora completamente assente.

Valutazione Qualitativa e Discussione

Come reso evidente dalla Figura 4.18 l’adozione di una funzione geometricamente più raffinata non riesce a impedire il collasso verso la posa media. Il volto generato mantiene infatti una postura del tutto immobile per l’intera durata del frammento.

Sebbene penalizzare l’errore nello spazio tridimensionale fornisca gradienti spazialmente più corretti questo approccio non scalfisce la vera radice del




Figura 4.18: Confronto qualitativo su un frammento di 5 secondi estratto da HDTF-TFHP (RD_AmandaStuck_000_chunk0). In alto la Ground Truth, in basso la predizione di EXP10 (FaceLoss). Nonostante l’ottimizzazione geometrica, il volto generato rimane in posizione statica per l’intera durata del frammento.

problema. La funzione di costo continua infatti a basarsi sull’Errore Quadratico Medio applicato a un dominio vocale *one-to-many*. L’ottimizzatore si trova di fronte a un input sonoro che ammette molteplici traiettorie visive altrettanto valide e per minimizzare l’errore globale sceglie matematicamente la via più sicura, ovvero la staticità.

4.10 EXP11 – Il termine di costo VarLoss

Motivazione

Gli esperimenti precedenti hanno dimostrato che la staticità delle predizioni è causata dalla natura stessa dell’Errore Quadratico Medio. In un task dalle molteplici soluzioni valide, una metrica basata sul rigido confronto fotogramma per fotogramma spinge inevitabilmente la rete a rifugiarsi nella posa media pur di minimizzare l’errore matematico. Per cercare di sbloccare i movimenti della testa e recuperare l’ampiezza delle oscillazioni naturali abbiamo quindi introdotto un termine di costo dedicato alla varianza tem-

porale, denominato **Variance Loss** ($\mathcal{L}_{\text{var}}$). Calcolando la differenza tra la dispersione della predizione e quella del dato reale costringiamo il modello a produrre un’escursione dinamica paragonabile a quella del video originale, superando di fatto l’ostacolo del perfetto allineamento temporale.

Configurazione

L’architettura di base e le impostazioni generali riprendono fedelmente il modello consolidato nei test precedenti. Vengono infatti mantenuti invariati l’encoder Wav2Vec 2.0 congelato, il modulo Bi-LSTM, il sistema di mappatura delle identità basato su codifica *One-Hot* con *prior* uniforme per i soggetti non noti e il calcolo della FaceLoss direttamente sui vertici 3D.

L’unica vera e sostanziale novità di questo esperimento riguarda la formulazione della funzione di costo complessiva $\mathcal{L}_{\text{total}}$, che ora unifica la supervisione geometrica e quella statistica secondo l’equazione

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{pos}} + w_{\text{vel}} \cdot \mathcal{L}_{\text{vel}} + w_{\text{var}} \cdot \mathcal{L}_{\text{var}}$$

La varianza temporale lungo i T frame reali di ciascuna sequenza b viene calcolata sui vertici 3D applicando la formula

$$\text{Var}_t(V[b]) = \frac{1}{T} \sum_{t=1}^T (V_t[b] - \bar{V}[b])^2 \in \mathbb{R}^{5023 \times 3}$$

Il nuovo termine statistico $\mathcal{L}_{\text{var}}$ viene quindi definito in modo diretto come l’Errore Quadratico Medio tra la varianza della predizione e quella del dato reale tramite l’espressione

$$\mathcal{L}_{\text{var}} = \text{MSE}(\text{Var}_t(V_{\text{pred}}), \text{Var}_t(V_{\text{target}}))$$

Per l’iperparametro associato alla varianza abbiamo adottato il valore $w_{\text{var}} = 5.0$. Poiché questa metrica calcola una dispersione quadratica media il

suo ordine di grandezza assoluto tende a essere numericamente molto ridotto. Il peso della perdita di velocità sui vertici rimane invece fissato a $w_{\text{vel}} = 1.0$.

L'addestramento è stato condotto sull'intero dataset HDTF-TFHP per 100 epoche con *batch size* pari a 4, impiegando l'ottimizzatore Adam con un tasso di apprendimento fisso a 10^{-4} e disabilitando le tecniche di *early stopping*.

Valutazione Quantitativa




Figura 4.19: Curve di addestramento e validazione per EXP11. La stella indica l'epoca corrispondente al minimo raggiunto durante la validazione.

Le curve riportate in Figura 4.19 descrivono l'andamento del processo di ottimizzazione. La funzione di costo in validazione tocca il suo minimo all'epoca 15 per poi intraprendere un percorso visibilmente altalenante. Come da protocollo standard la valutazione finale sul test set impiega i pesi estratti al termine della centesima e ultima epoca.

Modello	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP11 (VarLoss $w = 5$)	4.40°	5.16°	4.01°	4.52°	22.53	0.0046	0.00073

Tabella 4.14: Metriche quantitative per EXP11 sul test set aggregato di HDTF-TFHP.

Analizzando i risultati quantitativi in Tabella 4.14 emerge chiaramente come le metriche di errore globale rimangano sostanzialmente stazionarie ri-

spetto alle configurazioni precedenti. L'errore metrico sui vertici si attesta a 22.53mm risultando praticamente indistinguibile dai 22.60 mm di EXP10. Anche le velocità inter-frame non evidenziano scostamenti significativi confermando una sostanziale stabilità posizionale.

Un primo segnale di cambiamento emerge tuttavia dall'analisi della deviazione standard lungo la sequenza di benchmark. Il valore totale cresce infatti dell'11.9% rispetto a EXP10, un incremento trainato soprattutto dallo sblocco parziale degli assi *yaw* e *roll*. Purtroppo a fronte di una deviazione standard reale di circa 13.48° misurata sulla *ground truth* l'escursione complessiva prodotta dalla rete rimane confinata a soli 1.66° dimostrando che la dinamica del movimento risulta ancora fortemente compressa.

Valutazione Qualitativa e Discussione



Figura 4.20: Confronto qualitativo su un frammento di 5 secondi estratto da HDTF-TFHP (RD_AmandaStuck_000_chunk0). In alto la Ground Truth, in basso la predizione di EXP11 (VarLoss con peso $w_{\text{var}} = 5.0$). Nonostante l'introduzione della perdita sulla varianza, il volto generato evidenzia ancora una staticità marcata, del tutto simile agli esperimenti precedenti.

L'osservazione visiva dei fotogrammi in Figura 4.20 conferma i dati numerici. La testa predetta rimane quasi del tutto immobile e orientata rigidamente verso il centro, limitandosi a piccoli movimenti privi di espressività.

Si pensa che questo comportamento possa dipendere dallo squilibrio nei pesi della funzione di costo. La componente posizionale spinge infatti in modo dominante verso la posa media e l'importanza assegnata alla varianza risulta troppo debole per contrastarla; per sbloccare la dinamica del movimento nei futuri esperimenti sarà quindi indispensabile aumentare drasticamente il peso della VarLoss.

4.11 EXP12 – Standardizzazione della VarLoss

Motivazione

L'analisi di EXP11 ha dimostrato che un peso $w_{\text{var}} = 5.0$ non è assolutamente sufficiente per sbloccare la dinamica della testa. Un'indagine sui valori medi delle singole funzioni di costo registrati durante l'addestramento ha rivelato la radice del problema. Mentre la componente posizionale si attestava nell'ordine di grandezza di 10^{-5} e quella di velocità attorno a 10^{-7} , il termine di varianza produceva scalari minuscoli nell'ordine di 10^{-9} . A causa di questa enorme differenza la VarLoss pesava per meno dello 0.1% sul totale e il suo gradiente veniva letteralmente sommerso dalla PosLoss, che risultava oltre mille volte più grande costringendo la rete a convergere sulla posa media.

Per consentire alla varianza di influenzare attivamente l'apprendimento è indispensabile calibrare analiticamente i pesi. In questo dodicesimo esperimento abbiamo quindi stabilito una ripartizione strutturata per assegnare il 40% dell'influenza totale alla PosLoss, il 20% alla VelLoss e il restante 40% alla VarLoss.

Configurazione

Mantenendo come riferimento unitario il peso della componente di posizione ($w_{\text{pos}} = 1.0$), i nuovi pesi sono stati ricavati analiticamente imponendo le proporzioni target rispetto agli ordini di grandezza empirici:

1. **Peso Velocity Loss** (w_{vel}): per coprire il 20% del gradiente (rapporto 2 : 4 rispetto alla PosLoss):

$$w_{\text{vel}} = 0.5 \times \frac{\bar{m}_{\text{pos}}}{\bar{m}_{\text{vel}}} = 0.5 \times \frac{2.58 \times 10^{-5}}{3.57 \times 10^{-7}} \approx 36.13 \longrightarrow \mathbf{w_{vel} = 36} \quad (4.1)$$

con un incremento di $36\times$ rispetto a EXP11.

2. **Peso Variance Loss** (w_{var}): per coprire il 40% del gradiente (rapporto 4 : 4 paritario con la PosLoss):

$$w_{\text{var}} = 1.0 \times \frac{\bar{m}_{\text{pos}}}{\bar{m}_{\text{var}}} = 1.0 \times \frac{2.58 \times 10^{-5}}{3.57 \times 10^{-9}} \approx 7226.89 \longrightarrow \mathbf{w_{var} = 7200} \quad (4.2)$$

con un incremento di $1440\times$ rispetto al valore 5.0 adottato in EXP11.

La funzione di costo complessiva in EXP12 assume quindi la forma:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{pos}} + 36 \cdot \mathcal{L}_{\text{vel}} + 7200 \cdot \mathcal{L}_{\text{var}} \quad (4.3)$$

Per isolare l'effetto di questa singola modifica tutti gli altri iperparametri architetturali e le impostazioni di addestramento sono stati mantenuti rigorosamente identici a quelli di EXP11.

Valutazione Quantitativa




Figura 4.21: Curve di Training Loss (pannello sinistro) e Validation Loss (pannello destro) per EXP12 (VarLossStd con ribilanciamento dei pesi: $w_{\text{vel}} = 36$, $w_{\text{var}} = 7200$). La stella indica l'epoca di minimo della validation loss (Epoca 10, $\mathcal{L}_{\text{val}} \approx 6.61 \times 10^{-5}$).

Le curve di apprendimento riportate in Figura 4.21 illustrano l'andamento della loss complessiva ribilanciata. La Training Loss decresce regolarmente da 9.53×10^{-5} alla prima epoca fino a 5.58×10^{-5} alla centesima epoca. La Validation Loss raggiunge il minimo all'epoca 10 ($\mathcal{L}_{\text{val}} \approx 6.61 \times 10^{-5}$) per poi attestarsi su un plateau stabile attorno a 7.25×10^{-5} . In accordo con il protocollo adottato, la valutazione delle prestazioni sul test set è stata condotta impiegando i pesi dell'ultima epoca (epoca 100).

Modello	MAE Pitch	MAE Yaw	MAE Roll	MAE Tot.	MVE (mm)	VelMAE ang. (rad/f)	VelMAE mesh (m/f)
EXP12 (VarLossStd)	4.48°	5.21°	4.01°	4.57°	22.61	0.0043	0.00072

Tabella 4.15: Metriche quantitative per EXP12 sul test set aggregato di HDTF-TFHP (614 chunk, 283.359 frame totali).

I risultati quantitativi globali (Tabella 4.15) presentano valori quasi indistinguibili da quelli dei cicli precedenti: il MAE totale si attesta a 4.57° (Pitch 4.48°, Yaw 5.21°, Roll 4.01°) e l'errore metrico sui vertici (MVE) a 22.61 mm (rispetto ai 22.53 mm di EXP11 e 22.60 mm di EXP10). Le me-

triche di velocità (0.0043 rad/f e 0.00072 m/f) indicano un moto temporale estremamente piatto.

L’analisi diagnostica della deviazione standard condotta sul segmento di benchmark `RD_AmandaStuck_000_chunk0` rivela un fenomeno del tutto inatteso. Invece di sbloccarsi, la deviazione standard vettoriale totale crolla a 0.0148 rad , subendo un dimezzamento netto rispetto ai risultati di EXP11. Le oscillazioni sugli assi *yaw* e *roll* risultano in particolare quasi completamente azzerate e si riducono a frazioni infinitesimali di grado, creando una distanza abissale rispetto all’escursione di 0.2350 rad misurata nel video reale.

Valutazione Qualitativa e Discussione



Figura 4.22: Confronto qualitativo su un frammento di 5 secondi estratto da HDTF-TFHP (`RD_AmandaStuck_000_chunk0`). In alto la Ground Truth, in basso la predizione di EXP12 (`VarLossStd`). Anche a fronte di un forte incremento del peso della varianza, la testa generata rimane pressoché ferma per l’intera durata della sequenza.

L’osservazione dei risultati in Figura 4.22 e la visione del video confermano visivamente quanto suggerito dall’analisi statistica. Purtroppo la testa generata rimane ferma per l’intera durata dell’audio mostrando una staticità del tutto analoga a quella degli esperimenti precedenti. La posa predetta re-

sta congelata in una postura centrale neutra mentre il soggetto reale compie rotazioni e inclinazioni evidenti.

Capitolo 5

Conclusioni e Sviluppi Futuri

5.1 Conclusioni

Il percorso empirico sviluppato lungo dodici esperimenti ha messo in luce una complessità teorica profonda; mentre la fase di totale memorizzazione ha dimostrato che l'architettura possiede la capacità parametrica di riprodurre movimenti ampi e coerenti, ogni tentativo di generalizzazione su soggetti sconosciuti si è sistematicamente scontrato con il fenomeno del collasso verso la media. Di fronte a sequenze di test il modello ha prodotto traiettorie pressoché piatte, lasciando il volto congelato in una posa centrale.

Questa staticità costituisce il risultato scientificamente più significativo dell'indagine. A differenza dell'articolazione labiale che risponde a una rigida correlazione tra audio e movimento dettato dai fonemi pronunciati, il movimento del capo è una caratteristica intrinsecamente comportamentale e stocastica. Una medesima frase può essere accompagnata da un cenno di assenso, da un'inclinazione interrogativa o da una totale immobilità. A un singolo stimolo vocale corrispondono infatti molteplici traiettorie visive ugualmente plausibili.

All'interno di questo scenario *one to many* l'impiego dell'Errore Quadratico Medio impone alla rete una penalità severa per ogni deviazione rispetto all'esatta disposizione dei vertici tridimensionali in ogni singolo frame. Per minimizzare l'errore matematico atteso su una distribuzione di possibilità eterogenee, l'ottimizzatore sceglie inevitabilmente la via più conservativa convergendo sul baricentro statistico di tutte le traiettorie possibili. Poiché la media delle rotazioni di un parlatore coincide con la posizione neutra frontale il modello apprende che l'immobilità è la strategia più sicura per ridurre l'errore globale.

5.2 Sviluppi Futuri

Sulla base delle conclusioni raggiunte l'evoluzione naturale per superare il collasso alla media richiede l'abbandono dei regressori diretti in favore dei modelli generativi probabilistici. L'adozione di architetture a diffusione rappresenta oggi la soluzione più promettente. Invece di forzare il calcolo di un'unica traiettoria esatta queste reti imparano a generare movimenti realistici ripulendo progressivamente una sequenza iniziale di puro rumore. Questo meccanismo permette di mappare lo stesso input vocale su molteplici rotazioni del capo sempre diverse ma ugualmente valide e coerenti con la voce.

Questo approccio permette di risolvere alla radice il problema della regression to the mean. Ne è una chiara dimostrazione il recente successo dello stato dell'arte con DiffPoseTalk [12] capace di produrre risultati di altissima naturalezza. Affinché un simile approccio possa ereditare anche l'obiettivo di leggerezza computazionale perseguito in questo elaborato lo sforzo futuro dovrà concentrarsi sull'ottimizzazione del processo generativo riducendo i cal-

coli necessari per garantire la piena compatibilità con l'animazione interattiva in tempo reale.

Bibliografia

- [1] Alexei Baevski, Henry Zhou, Abdelrahman Mohamed, and Michael Auli. wav2vec 2.0: A framework for self-supervised learning of speech representations. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 33, pages 12449–12460, 2020.
- [2] Daniel Cudeiro, Timo Bolkart, Cassidy Laidlaw, Anurag Ranjan, and Michael J. Black. Capture, learning, and synthesis of 3D speaking styles. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10101–10111, 2019.
- [3] Radek Daněček, Kiran Chhatre, Shashank Tripathi, Yandong Wen, Michael J. Black, and Timo Bolkart. Emotional speech-driven animation with content-emotion disentanglement. In *SIGGRAPH Asia 2023 Conference Papers*, 2023.
- [4] Yingruo Fan, Zhaojiang Lin, Jun Saito, Wenping Wang, and Taku Komura. FaceFormer: Speech-driven 3D facial animation with transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 18765–18775, 2022.
- [5] Tianye Li, Timo Bolkart, Michael J. Black, Hao Li, and Javier Romero. Learning a model of facial shape and expression from 4D scans. *ACM*

- Transactions on Graphics*, 36(6):194:1–194:17, 2017.
- [6] Federico Nocentini, Thomas Besnier, Claudio Ferrari, Sylvain Arguillere, Stefano Berretti, and Mohamed Daoudi. Scantalk: 3d talking heads from unregistered scans. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2024.
- [7] Federico Nocentini, Claudio Ferrari, and Stefano Berretti. Speech-driven 3d facial animation with implicit emotional awareness: A coarse-to-fine approach. 2023.
- [8] Abraham Savitzky and Marcel J. E. Golay. Smoothing and differentiation of data by simplified least squares procedures. *Analytical Chemistry*, 36(8):1627–1639, 1964.
- [9] Nicholas Sharp, Souhaib Attaiki, Keenan Crane, and Maks Ovsjanikov. DiffusionNet: Discretization agnostic learning on surfaces. In *ACM Transactions on Graphics*, volume 41, pages 27:1–27:16. ACM, 2022.
- [10] Stefan Stan, Kazi Injamamul Haque, and Zerrin Yumak. FaceDiffuser: Speech-driven 3D facial animation synthesis using diffusion. In *Proceedings of the ACM SIGGRAPH Conference on Motion, Interaction and Games (MIG)*, 2023. arXiv:2309.11306.
- [11] Zhiyao Sun, Tian Lv, Sheng Ye, Matthieu Lin, Jenny Sheng, Yu-Hui Wen, Mingjing Yu, and Yong-Jin Liu. DiffPoseTalk: Speech-driven stylistic 3d facial animation and head pose generation via diffusion models. *ACM Transactions on Graphics*, 43(4), 2024.
- [12] Zhiyao Sun, Tian Lv, Sheng Ye, Matthieu Lin, Jenny Shum, and Yu-Hui Deng. Diffposetalk: Speech-driven stylistic 3d facial animation and head

- pose generation via diffusion models. *ACM Transactions on Graphics*, 43(4), 2024. arXiv:2310.00434.
- [13] Kaisiyuan Wang, Qianyi Wu, Linsen Song, Zhuoqian Yang, Wayne Wu, Chen Qian, Ran He, Yu Qiao, and Chen Change Loy. Mead: A large-scale audio-visual dataset for emotional talking-face generation. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2020.
- [14] Suzhen Wang, Lincheng Li, Yu Ding, Changjie Fan, and Xin Yu. Audio2Head: Audio-driven one-shot talking-head generation with natural head motion. In *Proceedings of the International Joint Conference on Artificial Intelligence (IJCAI)*, pages 1098–1105, 2021.
- [15] Jinbo Xing, Mengcheng Xia, Yuechen Zhang, Xiaodong Cun, Jue Wang, and Tien-Tsin Wong. CodeTalker: Speech-driven 3D facial animation with discrete motion prior. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 12780–12790, 2023.
- [16] Wenxuan Zhang, Xiaodong Cun, Xuan Wang, Yong Zhang, Xi Shen, Yu Guo, Ying Shan, and Fei Wang. SadTalker: Learning realistic 3d motion coefficients for stylized audio-driven single image talking face animation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 8652–8661, 2023.